

یادگیری ارجحیت فازی

داریوش حسن پور آده

دانشگاه صنعتی اصفهان، دانشکده مهندسی برق و کامپیوتر

Email: d.hasanpoor@ec.iut.ac.ir

پیش‌بینی کردن رابطه‌ی ترتیب^۳ در مجموعه‌ای از اشیا گفت. [۲] یادگیری ارجحیت از داده‌های اطلاعات ارجحیت^۴ برای اهداف یادگیری خود استفاده می‌کند که این اطلاعات ارجحیت نقش مهمی در تصمیم‌گیری‌های خودکار در زمینه‌های متعددی مانند تئوری تصمیم‌گیری‌های کیفی^۵، استدلال غیریک‌نواخت^۶، رضای محدودیت^۷ و طرح‌ریزی^۸ و ... کاربردهای فراوانی دارد. در مرحله ی آموزش، الگوریتم‌های یادگیری ارجحیت به داده‌های ترتیب رتبه بندی^۹ (نیمه) شناخته شده عناصر دسترسی دارند. بسته به مدل و نوع مساله الگوریتم‌های یادگیری ارجحیت می‌توانند به ۳ دسته ی رتبه‌بندی اشیا^{۱۰}، رتبه‌بندی برچسب‌ها^{۱۱} و رتبه‌بندی نمونه‌ها^{۱۲} تقسیم‌بندی کرد.

در این نوشتار ابتدا مقدمه‌ای بر مفاهیم بنیادی مطرح در یادگیری ارجحیت آورده شده است و در نهایت با تمرکز بر مقاله اصلی سمینار شرح مفصلی در مورد یادگیری ارجحیت فازی ارائه خواهیم داد.

چکیده—یادگیری ارجحیت یکی از زیررشته‌های یادگیری ماشین می‌باشد که هدف اصلی‌اش یادگیری ارجحیت‌های قابل پیش‌بینی از روی اطلاعات ارجحیت می‌باشد. از نقطه نظر یادگیری باناظر یادگیری ارجحیت روی یک دسته از عناصر که نسبت به یک دسته از برچسب‌ها یا عناصر ارجحیت بیشتری دارند آموزش داده می‌شوند که بتواند در نهایت مدل ارجحیت عناصر دیده نشده را پیش‌بینی کند. یادگیری ارجحیت فازی ترکیبی از یادگیری ماشین و سیستم‌های فازی می‌باشد که سعی در یادگیری ارجحیت عناصر از طریق یادگیری یک تابع رتبه‌بند با استفاده از منطق فازی می‌باشد.

کلمات کلیدی — یادگیری ارجحیت، یادگیری ارجحیت فازی، تابع ارجحیت، طبقه‌بندی

۱ مقدمه

یادگیری ارجحیت^۱ یکی از شاخه‌های یادگیری ماشین^۲ می‌باشد که در سال‌های اخیر توجه زیادی را به سمت خود جلب کرده است. وظیفه‌ی اصلی یادگیری ارجحیت، یادگیری رتبه‌بندی کردن عناصر می‌باشد. که با توجه به نوع اطلاعات آموزشی نوع ارجحیت و همچنین نوع رتبه‌بندی می‌تواند تغییر کند. در حالت کلی یادگیری ارجحیت به استنتاج کردن ارتباطات بین اعضای یک دسته و نگاشت این ارتباطات به مدلی که بتواند ارجحیت نسبی موجود بین اعضای این دسته بخوبی پیش‌بینی کند.

اگر بخواهیم تعریف دقیقی برای یادگیری ارجحیت ارائه دهیم می‌توانیم بگوییم که یادگیری ارجحیت به وظیفه‌ی یادگیری

Order^۳
Preference Information^۴
Qualitative decision theory^۵
Non-monotonic reasoning^۶
Constraint satisfaction^۷
Planning^۸
Ranking Order^۹
Object Ranking^{۱۰}
Label Ranking^{۱۱}
Instance Ranking^{۱۲}

Preference Learning^۱
Machine Learning^۲

۲ یادگیری ارجحیت

واقع فرمت^{۱۶} خروجی کلی الگوریتم‌های یادگیری ارجحیت را ارائه می‌دهد، به گونه‌ای که خروجی ارجحیت ورودی‌ها یک جایگشتی اندیسی^{۱۷} ترتیب‌اکید ارجحیت‌های ورودی‌ها می‌باشد بگونه‌ای که اندیس آن جایگزینی که دارای ارجحیت بیشتری نسبت به دیگری است، در مجموعه‌ی τ مقدم‌تر از دیگری می‌آید.

طبق آنچه که در تعریف ۳.۲ آمده، واضح است که الگوریتم‌های یادگیری ارجحیت در واقع یک جستجوکننده در فضای جایگشتی مجموعه τ می‌باشد؛ فضای جایگشت‌های τ را با S_m نمایش می‌دهند.

۲.۲ انواع الگوریتم‌های رتبه‌بندی

الگوریتم‌های رتبه‌بندی از نظر نوع وظیفه‌ای که به عهده دارند به ۳ تیپ تقسیم‌بندی می‌شوند که عبارتند از رتبه‌بندی برچسب‌ها، رتبه‌بندی اشیاء و رتبه‌بندی نمونه‌ها؛ که در این قسمت شرح مختصری از این ۳ تیپ الگوریتم ارائه خواهیم داد. [۲]

۱.۲.۲ رتبه‌بندی برچسب‌ها: در این رتبه‌بندی هدف این است که به ازای یک نمونه برچسب‌ها را براساس ارجحیت مرتب کند. شمایک ورودی‌ها و خروجی‌ها این نوع الگوریتم در شکل ۱ آمده است.

Given:

- A set of training instances $\{x_k | k=1, \dots, n\} \subseteq \mathcal{X}$ (each instance typically represented by a feature vector)
- A set of labels $\mathcal{L} = \{\lambda_i | i=1, \dots, m\}$
- For each training instance x_k : a set of associated pairwise preferences of the form $\lambda_i \succ_{x_k} \lambda_j$

Find:

- A ranking function in the form of an $\mathcal{X} \rightarrow S_m$ mapping that assigns a ranking (permutation) \succ_x of \mathcal{L} to every $x \in \mathcal{X}$

شکل ۱: شمایک کلی الگوریتم‌های رتبه‌بندی برچسب‌ها

همانطور که در شکل ۱ آمده است الگوریتم‌های رتبه‌بندی برچسب‌ها تعدادی نمونه‌ی آموزشی می‌گیرد که این نمونه‌های

برای اینکه بتوانیم یادگیری ارجحیت فازی را ارائه دهیم نیاز هست که در این قسمت به معرفی خلاصه‌ای از مفاهیم اولیه و بنیادی زمینه‌ی یادگیری ارجحیت پردازیم.

۱.۲ نمادگذاری

طبق هر شاخه‌ی علمی دیگر به یک سری نماد برای پایه گذاری یادگیری ارجحیت نیاز داریم که در این قسمت به معرفی آن‌ها می‌پردازیم.

تعریف ۱.۲ (ارجحیت ضعیف): یک ارجحیت ضعیف با نماد \succeq بروی مجموعه‌ای مانند A یک رابطه‌ی بازتابی و تعددی می‌باشد.

تعریف ۲.۲ (ارجحیت اکید): $a \succ b \leftrightarrow (a \succeq b) \wedge (b \not\succeq a)$

در راستای معناشناسی یادگیری ارجحیت تعاریف ۱.۲ و ۲.۲ می‌توان آن‌ها را به صورت جدول ۱ تعبیر کرد.

نماد	تعبیر
$a \succeq b$	"جایگزین a حداقل به اندازه‌ی جایگزین b ترجیح داده می‌شود."
$a \succ b$	"جایگزین a بیشتر از جایگزین b ترجیح داده می‌شود."

جدول ۱: تعبیر نمادهای روابط ارجحیت

تعریف ۳.۲ (ترتیب/اکید کلی^{۱۳} - رتبه‌بندی^{۱۴}): اگر A یک مجموعه‌ای از اشیاء / جایگزین‌ها^{۱۵} $\{a_1, \dots, a_m\}$ باشد، یک رتبه‌بندی از A یک جایگشتی همانند τ از مجموعه‌ی $\{1, \dots, m\}$ می‌باشد بگونه‌ای که $a_i \succ a_j \leftrightarrow \tau(i) < \tau(j)$.

در تعریف ۳.۲ مقدار m تعداد اشیاء/جایگزین‌ها و a_i ‌ها همان اشیاء/جایگزین‌ها می‌باشند، که از این به بعد به مجموعه‌ی اشیاء یا جایگزین‌ها، فقط جایگزین گفته خواهد شد. تعریف ۳.۲ در

^{۱۳}Total Strict Order

^{۱۴}Order

^{۱۵}Alternatives

^{۱۶}Format

^{۱۷}Index Permutation

است در کاربردهای دنیای واقعی این الگوریتم تمامی ارجحیت های موجود بین اشیا شناخته نشده باشد. دومین دلیل این است که در صورتی که تمامی ارجحیت های بین اشیا شناخته شده باشد اندازه ی مجموعه ی مرتب از ارجحیت خیلی بیشتر از تعداد اشیا می باشد؛ که از حل ۱ می بینیم این افزونگی داده ای تقریباً $\frac{n}{2}$ برابر تعداد اشیا می باشد که در کاربردهای واقعی این الگوریتم ها معمولاً تعداد اشیا زیاد است که در نتیجه تعداد ارتباطات مرتب بین آنها بسیار بیشتر از تعداد اشیا می باشد که مشکلات خواص خودش را در پی دارد که خارج از حیطه ی این نوشتار است.

$$\binom{n}{2} = \frac{n-1}{2} \quad (1)$$

در نتیجه این شرط که الگوریتم های رتبه بندی اشیا تنها با در اختیار داشتن مجموعه ی تکه ای مرتب از ارجحیت های میان اشیا باید بتواند مدلی برای رتبه بندی اشیا بدست بیاورد؛ باعث می شود که این الگوریتم های در کاربردهای دنیای واقعی کاربرد پیدا کند.

۳.۲.۲ رتبه بندی نمونه: رتبه بندی نمونه همانند رتبه بندی اشیا می باشد یعنی علاوه بر شماتیک معرفی شده در رتبه بندی اشیا ۲ عدد ورودی دیگر را نیز دارد. به این صورت که یک مجموعه اکیدا مرتب (تعریف ۲.۲ را ببینید) از برچسب ها را نیز اختیار می کند که در این مجموعه مرتب از برچسب ها آن برچسبی که دارای ارجحیت بیشتری است در ابتدای مجموعه ظاهر شود. و همچنین یک ورودی دیگر نیز به الگوریتم داده می شود که مجموعه ارتباطات یک به یک از هر کدام از اشیا را به برچسب متعلق به آن شی می باشد. همچنین در این نوع از الگوریتم ها نیازی به مجموعه (تکه ای) مرتب از ارجحیت های نسبی اشیا به الگوریتم داده شود.

۳.۲ موارد خاص یادگیری/ارجحیت

همان طور که در قسمت ۲.۲ آمده است الگوریتم های یادگیری ارجحیت از نظر اهداف و کاربرد با یک دیگر متفاوت هستند، ما همه روزه در میان الگوریتم های طبقه بندی روزمره ای که با آنها سروکار داریم در واقع داریم از الگوریتم های ارجحیت استفاده می

آموزشی معمولاً به صورت بردار ویژگی ها نمایش داده می شود. سپس یک سری برچسب و همچنین به ازای هر کدام از نمونه ها یک مجموعه ی دوبه دو مرتب که ارجحیت برچسب ها برای هر کدام از نمونه ها مشخص شده است را به عنوان ورودی به الگوریتم داده می شود. الگوریتم های متعلق به رتبه بندی برچسب ها باید به عنوان خروجی یک تابع رتبه بند است که بتواند به ازای یک شی جایگشت های برچسب های متعلق به آن شی را با توجه به ارجحیتی که دارند برگرداند.

۲.۲.۲ رتبه بندی اشیا: در این رتبه بندی هدف این است که یک دسته از اشیا را برحسب ارجحیتی که نسبت به هم دارند، را مرتب سازی کنیم. که شماتیک ورودی ها و خروجی ها این نوع الگوریتم در شکل ۲ آمده است.

Given:

- A (potentially infinite) set \mathcal{X} of objects (each object typically represented by a feature vector)
- A finite set of pairwise preferences $x_i > x_j, (x_i, x_j) \in \mathcal{X} \times \mathcal{X}$

Find:

- A ranking function $r(\cdot)$ that, given a set of objects $\mathcal{O} \subseteq \mathcal{X}$ as input, returns a permutation (ranking) of these objects

شکل ۲: شماتیک کلی الگوریتم های رتبه بندی اشیا

در شماتیکی که در شکل ۲ آمده است می بینیم که همانند رتبه بندی برچسب ها یک دسته از اشیا را به عنوان ورودی می گیرد. سپس یک دسته ی (تکه ای) مرتب از ارجحیت های نسبی این اشیا را نیز به عنوان ورودی به الگوریتم می دهیم و نهایت الگوریتم باید یک تابع رتبه بند را بیابد که بتواند ارجحیت های هر زیرمجموعه از مجموعه ی جهانی اشیا را در قالب یک جایگشتی از اشیا ورودی به عنوان خروجی برگرداند.

توجه شود که مجموعه ی (تکه ای) مرتب از ارجحیت اشیا که به عنوان داده آموزشی به الگوریتم داده می شود نیازی ندارد که تمامی ارجحیت های موجود میان اشیا را شامل باشد، به چند دلیل این شرط می تواند به قابل پیاده سازی بودن الگوریتم کمک زیادی کند. اولین دلیل که بدیهی ترین دلیل می باشد، این است که ممکن

توان طبقه‌بند چند برچسب را به صورت تعریف ۳ با استفاده از رتبه بند ارجحیت مدل کرد.

$$C_{x_k} = \{L_k \mid \lambda_i \succ_{x_k} \lambda_j, \lambda_i \in L_k, \lambda_j \in L \setminus L_k\} \quad (3)$$

۴.۲ انواع روش‌های یادگیری ارجحیت

برای یادگیری ارجحیت دو روش معمول موجود است که یکی بر اساس یادگیری یک تابع سودمندی^{۲۰} و دیگری یادگیری ارتباطات ارجحیت^{۲۱} موجود بین داده‌ها را یاد می‌گیرد که برای درک بهتر روش ارائه شده در مقاله اصلی در این بخش به توضیح مختصری نسبت به هریک می‌پردازیم.

۱.۴.۲ یادگیری تابع سودمندی: یک راه طبیعی برای نشان دادن ارجحیت‌های موجود بین داده‌ها این است که جایگزین‌های موجود را با استفاده از یک تابع مطلوبیت ارزیابی کنیم. برای رتبه بندی اشیا یک تابع نگاشت $f: \mathcal{X} \rightarrow \mathcal{U}$ که مقدار سودمندی $f(x)$ به هریک از اشیا x تخصیص می‌دهد را یاد می‌گیریم و در نهایت اشیا را با معیار سودمندی‌ای که از این تابع سودمندی یادگرفته شده محاسبه می‌شود مرتب کرده و به عنوان خروجی برمی‌گردانیم. و در رتبه‌بندی برچسب‌ها به ازای هریک از برچسب‌ها $\lambda_i, i = 1, \dots, m$ یک تابع سودمندی $f_i: \mathcal{X} \rightarrow \mathcal{U}$ یادگرفته می‌شود و در نهایت برچسب‌ها را برحسب مقدار سودمندی‌ای که آن برچسب‌ها دارند مرتب می‌کنیم، $\lambda_i \succ_x \lambda_j \Rightarrow f_i(x) \geq f_j(x)$.

۵.۲ یادگیری ارتباطات ارجحیت

یک روش معمول دیگر در یادگیری ارجحیت این است که بیایم و ارتباطات ارجحیت دودویی موجود بین دو اشیا (برچسب) ها را یاد بگیریم. برای رتبه‌بندی اشیا یک تابع ارجحیت دودویی مانند $Q(x, x')$ یاد می‌گیرد که نشان می‌دهد آیا شی x نسبت به x'

کنیم که در اینجا به معرفی دو نوع از الگوریتم‌های طبقه‌بندی می‌پردازیم که حالت خاصی از الگوریتم‌های یادگیری ارجحیت می‌باشند.

۱.۳.۲ طبقه‌بندی: الگوریتم‌های طبقه‌بند^{۱۸} که همه روزه از آن‌ها استفاده می‌کنیم در واقع حالت خاصی از الگوریتم‌های رتبه بندی برچسب‌ها می‌باشد. از آنجایی که در طبقه‌بندی به ازای یک ورودی هدف پیش‌بینی برچسب مرتبط با آن ورودی می‌باشد، می‌توان داده‌ی ورودی را به یکی از الگوریتم‌های یادگیری ارجحیت (رتبه‌بندی برچسب‌ها) داد سپس از میان مجموعه جایگشت برچسب‌ها که به عنوان خروجی رتبه‌بند برگشت داده خواهد شد، آن برچسبی را که دارای بیشتری ارجحیت است را به عنوان برچسب منتخب برای آن نمونه ورودی انتصاب کرد. به عبارت دیگر می‌توان با استفاده از تعریف ۲ الگوریتم‌های طبقه‌بند را با استفاده از رتبه‌بند برچسب‌های یادگیری ارجحیت مدل کرد.

$$C_{x_k} = \{\lambda_i \mid \lambda_i \succ_{x_k} \lambda_j, 1 \leq j \neq i \leq m\} \quad (2)$$

۲.۳.۲ طبقه‌بندی چند برچسب: در طبقه‌بندی چند برچسب^{۱۹} هر نمونه به یک زیرمجموعه‌ای از برچسب‌ها نسبت داده می‌شود. این نوع از الگوریتم‌ها را نیز حالت خاصی از الگوریتم‌های یادگیری ارجحیت (رتبه‌بندی برچسب‌ها) می‌باشد به گونه‌ای که الگوریتم رتبه‌بندی برچسب‌ها یک عدد به عنوان تعداد برچسب‌های نسبت داده شده به اشیا داده می‌شود و الگوریتم بعد از مرتب‌سازی برچسب‌ها بر اساس ارجحیت‌هایی که دارند یک تعداد از برچسب‌ها که دارای ارجحیت بیشتری می‌باشند را به عنوان خروجی بر می‌گرداند. یا یک روش دیگر برای مدل کردن طبقه بند چند برچسب با استفاده از رتبه‌بند برچسب‌ها این است که در کنار داده‌های الگوریتم یک حد آستانه مابین $[0, 1]$ به الگوریتم داده شود و بعد از رتبه‌بندی برچسب‌ها و نرمال‌سازی میزان ارجحیت‌های برچسب‌ها آن برچسب‌هایی که میزان ارجحیت آن‌ها بیشتر از حد آستانه به عنوان خروجی برگشت داده شود. در حالت کلی می

۱.۳ اندازه‌گیری غیرافزایشی

برای ارائه‌ی یک دید کاربردی از معنی و مفهوم اندازه‌گیری غیرافزایشی، در این قسمت سعی شده است که این ویژگی را متناسب با کاربردش در یادگیری ارجحیت با یک مثال فرضی ارائه دهیم.

فرض کنیم که یک مدرسه وجود دارد که به دانش مهندسی دانشجویان‌اش بیشتر از دانش ادبی آن‌ها اهمیت می‌دهد. همچنین در سیاست‌های این آموزشگاه آمده است که بهتر است دانش‌آموختگانی پرورش دهیم که در تمامی علوم آموزش داده‌شده، دارای دانش متعادلی باشند. حال اگر فرض کنیم تنها ۳ درس ریاضی، فیزیک و ادبیات در این آموزشگاه آموزش داده می‌شود طبق اولین سیاست این آموزشگاه که به دانش مهندسی بیشتر از دانش ادبی بها می‌دهد، به نمرات ریاضی و فیزیک دانشجویان وزن بیشتری می‌دهد ولی از طرف دیگر طبق سیاست دوم به دانشجویانی که نمرات متعادل‌تری نسبت به دیگری که واریانس نمرات آن‌ها زیاد است اهمیت نیز می‌دهد.

حال اگر بخواهیم طبق این سیاست‌ها یک اندازه‌گیر تعریف کنیم، مثلاً می‌توانیم اندازه‌های زیر را ارائه دهیم که با جزئیات مساله سازگارند.

$$\mu(\{1, 2, 3\}) = 1, \quad \mu(\{\emptyset\}) = 0$$

$$\mu(\{1\}) = \mu(\{2\}) = 0.45, \quad \mu(\{3\}) = 0.3$$

$$\mu(\{1, 3\}) = \mu(\{2, 3\}) = 0.9, \quad \mu(\{1, 2\}) = 0.5$$

که در اینجا طبق آنچه که در اندازه‌گیری‌های بالا مطرح شده است هر یک از دروس ریاضی، فیزیک و ادبیات به ترتیب با اعداد ۱ و ۲ و ۳ نمایش داده می‌شوند، و می‌توان این تفصیر را کرد که دانشجوی در تمامی دروس خود خوب عمل می‌کند دارای حداکثر درجه‌ی اهمیت یعنی مقدار ۱ برای آموزشگاه می‌باشد و دانشجویانی که در هیچ یک از دروس خوب عمل نمی‌کند اهمیتی برای گروه آموزشی آموزشگاه ندارند و کسب نمره‌ی خوب در هر یک از دروس ریاضی یا فیزیک به تنهایی دارای درجه‌ی اهمیت یکسان ۰.۴۵ می‌باشد این مقدار بیشتر از مقدار درجه‌ی اهمیتی است که برای درس ادبیات

ارجحیت دارد یا خیر. در نهایت ترتیب نهایی شامل یک جایگشتی می‌باشد که حداکثر سازگاری را با این ترتیب‌های دودویی داشته باشند. به عبارت دیگر جایگشتی را انتخاب می‌کنیم که مقدار ۴ را حداکثر کند.

$$V_{\mathcal{X}} = \sum_{i=1}^n \sum_{j \neq i=1}^n Q(x_i, x_j) \quad (4)$$

برای رتبه‌بندی برچسب‌ها هم یک روشی به نام طبقه‌بندی دویه‌دو ارائه شده است. ایده‌ی این طبقه‌بند دویه‌دو این است که به ازای هریک از برچسب‌ها یک مدلی مانند $(\lambda_i, \lambda_j) \in \mathcal{L}, 1 \leq i < j \leq m, M_{i,j}$ را با استفاده از داده‌های آموزشی بدست بیاوریم (یاد بگیریم)؛ در نتیجه به تعداد $\frac{m(m-1)}{2}$ تعداد مدل نیاز داریم. داده‌های آموزشی شامل اطلاعات ارجحیت برچسب‌ها مانند $\lambda_i \succ_x \lambda_j$ می‌باشند که به صورت مثال های آموزشی (a, b) تبدیل می‌شوند که برای یادگیری مدل $M_{a,b}$ استفاده می‌شوند. درواقع مدل $M_{a,b}$ سعی بر یادگیری مدلی دارد که نگاشت ۵ را انجام دهد.

$$M_{a,b} \mapsto \begin{cases} 1 & \lambda_a \succ_x \lambda_b \\ 0 & \lambda_b \succ_x \lambda_a \end{cases} \quad (5)$$

که این نگاشت می‌تواند توسط یکی از طبقه‌بند کننده‌های دودویی انجام گیرد.

۳ یادگیری ارجحیت فازی

مقاله اصلی [۱] یادگیری ارجحیت را با استفاده از انتگرال چوکت^{۲۲} پیاده‌سازی کرده است. که در این قسمت بعد از یادآوری اندازه‌گیری غیرافزایشی^{۲۳} و اینکه چرا انتگرال چوکت می‌تواند برای حل چنین مساله‌ای مفید باشد بحثی خواهیم داشت؛ سپس مروری بر انتگرال چوکت و در انتها روش اصلی ارائه شده در مقاله اصلی را بیان می‌کنیم. نتایج حاصله نیز در بخش بعدی این نوشتار به تفصیل آمده است.

مساله یک اندازه گیری غیرافزایشی می باشد. در اکثر مسائل یادگیری ارجحیت نوع ارتباطات میان ارجحیت ها از نوع اندازه گیری های غیرافزایشی می باشد. به همین علت و طبق آنچه که در مورد انتگرال چوکت مشهور است که به خوبی می تواند با اندازه گیری های غیرافزایشی کار کند منطقی به نظر می رسد که ترکیب این دو مساله، یعنی یادگیری ارجحیت و انتگرال چوکت می تواند منجر به نتیجه ای خوب شود. که همین دلیل انگیزه ی اصلی مطرح شده در مقاله نسبت به اینکه چرا از انتگرال فازی چوکت برای یادگیری ارجحیت استفاده شده است.

۲.۳ / اهمیت معیارها

اندازه گیری های افزایشی را می توان به صورت زیر نمایش

داد،

$$\mu(A) = \sum_{x_i \in A} \mu(\{x_i\}) = \sum_{x_i \in A} w_i$$

که اندازه ی گیری $w_i = \mu(\{x_i\})$ وزن معیار x_i می باشد. طبق آنچه که در ۷ و ۸ آمده است این وزن ها غیر صفر و $\sum_{i=1}^n w_i = 1$ می باشند. که در اینجا آنچه که واضح است این است که میان معیار ها (x_i ها) هیچ ارتباطی وجود ندارد؛ یعنی اندازه گیری روی معیار x_i مستقل از نتیجه ی اندازه گیری انجام شده روی معیار x_j می باشد.

حس ضرورت اندازه گیری اهمیت معیارها زمانی پدیدار می شود که اندازه گیری ما از نوع غیرافزایشی باشد. حال فرض کنید یک اندازه گیر فازی μ بروی مجموعه ای از معیارها مانند X داده شده است. میزان اهمیت معیار x_i به صورت میانگین میزان افزایش اهمیت با اضافه کرده معیار x_i به یک مجموعه ی دیگر مانند $A \subset X \setminus \{x_i\}$ که این میانگین گیری را می توان توسط رابطه ی ۱۲ نمایش داد.

$$\varphi(x_i) = \frac{1}{n} \sum_{A \subset X \setminus \{x_i\}} \frac{1}{\binom{n-1}{|A|}} (\mu(A \cup \{x_i\}) - \mu(A)) \quad (12)$$

که میزان اهمیت معیارها روی یک اندازه گیر مانند μ توسط یک برداری همانند $\varphi(\mu, X) = \langle \varphi(x_1), \dots, \varphi(x_n) \rangle$ نشان داده

گذاشته که مقدار ۰.۳ تخصیص داده شده است می باشد. و در انتها دانشجویانی که در کنار یکی از دروس ریاضی یا فیزیک، در درس ادبیات نیز نمره ی خوبی کسب کرده باشد دارای درجه ی اهمیت بیشتری نسبت به دانشجویانی که فقط در درس ریاضی یا فیزیک نمره خوبی کسب کرده اند می باشد. که در اندازه گیری های ارائه شده برای این مثال می توان ارتباط ۶ را مشاهده می کنیم.

$$\mu(\{1, 2\}) \neq \mu(\{1\}) + \mu(\{2\}) \quad (6)$$

که رابطه ی ۶ در واقع تعریف اندازه گیری های غیرافزایشی می باشد. که در حالت کلی برای اندازه گیری های که خواص ۷...۹ را دارند، اندازه گیری های غیرافزایشی می گویند.

$$\mu(\emptyset) = 0, \mu(X) = 1 \quad (7)$$

$$\mu(A) \leq \mu(B) \quad \forall A \subseteq B \subseteq X \quad (8)$$

$$\mu(\{a_1, \dots, a_k\}) \neq \sum_{i=1}^k \mu(\{a_i\}) \quad (9)$$

یکی از روش های مفید ارائه شده برای نمایش اندازه گیری های غیرافزایشی که در مقاله کمک زیاد برای یادگیری مدل ارجحیت کرده است نگاشت مویوس^{۲۴} می باشد که به صورت ۱۰ تعریف می شود.

$$\mu(B) = \sum_{A \subseteq B} m(A) \quad (10)$$

به ازای تمامی $B \subseteq X$ که نگاشت مویوس $m_{\hat{\mu}}$ را که اندازه ی $\hat{\mu}$ به صورت ۱۱ تعریف می شود.

$$m_{\hat{\mu}}(A) = \sum_{v \subseteq A} (-1)^{|A|-|v|} \hat{\mu}(v) \quad (11)$$

که در واقع مقدار بدست آمده از ۱۱ در واقع می توان به عنوان وزن ارزشی ای است که اختصاصا به مجموعه ی A داده شده است و ارزش ارتباطات غیرمستقیم اجزای تشکیل دهنده ی آن مجموعه حذف گردیده است.

آنچه که در مثال ابتدای این بخش دیدیم در واقع یک مساله ی یادگیری ارجحیت می باشد، که دیدم ارجحیت های این

می شود که دارای خواص ۱۳ و ۱۴ می باشد.

$$0 \leq \varphi(x_i) \leq 1 \quad (13)$$

$$\sum_{i=1}^n \varphi(x_i) = 1 \quad (14)$$

۳.۳ انتگرال چوکت

در این قسمت مروری خلاصه بر انتگرال چوکت که مورد

استفاده در مقاله اصلی صورت گرفته است، می کنیم و سپس با استفاده از نگاشت مویوس که در بخش ۳.۱ تعریف شد تبدیلی رو انتگرال چوکت اعمال می کنیم که در نهایت مساله ی یادگیری ارجحیت به یک مساله ی بهینه سازی تبدیل شود^{۲۶}.

همان طور که می دانیم رابطه ی انتگرال چوکت به صورت ۱۵

بیان می شود [۳].

$$\begin{aligned} C_\mu(f) &= \sum_{i=1}^n (f(x_{(i)}) - f(x_{(i-1)})) \cdot \sum_{k=i}^n \mu(\{x_{(k)}\}) \\ &= \sum_{i=1}^n (f(x_{(i)}) - f(x_{(i-1)})) \cdot \mu(A_{(i)}) \end{aligned} \quad (15)$$

بگونه ای که (\cdot) یک جایگشتی از مجموعه ی \mathcal{S}_m است بگونه ای

که $f(x_{(o)}) = 0$ که $0 \leq f(x_{(1)}) \leq f(x_{(2)}) \leq \dots \leq f(x_{(n)})$ تعریف شده است و $A_{(i)} = \{x_{(i)}, \dots, x_{(n)}\}$.

حال اگر بخواهیم انتگرال چوکت را از نظر ظاهری با آنچه

که برای میزان اهمیت معیارها در بخش ۳.۲ گفته شد براحتی قابل اثبات است که تابع انتگرال چوکت را می توان به صورت ۱۶ بازنویسی کرد.

$$\begin{aligned} C_\mu(f) &= \sum_{i=1}^n (f(x_{(i)}) - f(x_{(i-1)})) \cdot \mu(A_{(i)}) \\ &= \sum_{i=1}^n f(x_{(i)}) \cdot (\mu(A_{(i)}) - \mu(A_{(i+1)})) \end{aligned} \quad (16)$$

حال اگر نگاشت مویوس را بر معادله ی بازنویسی شده چوکت در

^{۲۶} بنابه اینکه انتگرال چوکت جز سرفصل های تدریس شده در کلاس بوده و کاملاً با مفهوم این انتگرال فازی آشنا هستیم از توضیح راجع به جزئیات بنیادی این انتگرال خودداری می کنیم.

۱۶ اعمال کنیم به روابط ۱۷ می رسیم.

$$C_\mu(f) = \sum_{i=1}^n f(x_{(i)}) \cdot (\mu(A_{(i)}) - \mu(A_{(i+1)})) \quad (17)$$

$$\begin{aligned} &= \sum_{i=1}^n f(x_{(i)}) \cdot \sum_{R \subseteq T} m(R) \\ &= \sum_{T \subseteq \mathcal{X}} m(T) \times \min_{x_i \in T} f(x_i) \\ &= \sum_{T \subseteq \mathcal{X}} \sum_{v \subseteq T} (-1)^{|A|-|v|} \mu(v) \times \min_{x_i \in T} f(x_i) \end{aligned} \quad (18)$$

$$T = \{G \cup \{x_{(i)}\} \mid G \subset \{x_{(i+1)}, \dots, x_{(n)}\}\} \quad (19)$$

که در ۱۸ تنها چیزی که نامعلوم است مقدار μ می باشد که در بخش بعدی توضیح داده خواهد شد که چگونه یاد گرفته خواهد شد و می توان به صورت بردار ضرب داخلی 2^o نوشت.

$$\langle m_\varphi, \varphi(f(x)) \rangle \quad (20)$$

که نگاشت $\mathbb{R}^n \rightarrow \mathbb{R}^{2^n-1} : \varphi$ به صورت ۲۱ تعریف می کنیم.

$$\begin{aligned} \varphi(x) &= \varphi(x_1, \dots, x_2) \\ &= (x_1, \dots, x_n, \min\{x_1, x_2\}, \dots, \min\{x_{n-1}, x_n\}, \\ &\quad \min\{x_1, x_2, x_3\}, \dots, \min\{x_1, \dots, x_n\}) \end{aligned} \quad (21)$$

که m_φ ماتریس $\langle m_1, \dots, m_n, m_{n+1}, \dots, m_{2^n-1} \rangle$ مقادیر بدست آمده توسط نگاشت مویوس می باشد که ترتیبش توسط $\varphi(x)$ تعیین می شود.

۴.۳ یادگیری ارجحیت با استفاده از انتگرال چوکت

ایده این مقاله این است که برای رتبه بندی اشیا که در بخش ۲.۲.۲ معرفی شد، بیاییم تابع رتبه بند را در قالب انتگرال چوکت ارائه دهیم. اگر فرض کنیم که هریک از اشیا مانند $o \in \mathcal{O}$ به صورت یک برداری از ویژگی ها نمایش دهیم.

$$f_o = (f_o(x_1), \dots, f_o(x_n))$$

غیرممکن است در نتیجه هر شی o_s با یک متغیر ضعیف ξ_s همانند ξ_s در ارتباط است. که این متغیرهای ضعیف نامنفی هستند و مقدار مثبت این متغیر جرمه‌ای متناسب با اندازه خودش تحمیل متحمل می‌شود. و در نهایت γ یک مقدار موازنه γ می‌باشد که هرچقدر مقدارش بیشتر باشد میزان جرمه‌ی تحمیل شده از سوی متغیرهای ضعیف بیشتر می‌باشد.

$$C_\mu(f_{o_s}) - C_\mu(f_{o_t}) > M - \xi_s - \xi_t \quad \forall (o_s, o_t) \in \mathcal{D} \quad (24)$$

$$\xi_s \geq 0 \quad (25)$$

$$\sum_{T \subseteq X} m(T) = 1 \quad (26)$$

$$\sum_{B \subseteq A} m(B) \geq 0 \quad \forall A \subseteq X \quad (27)$$

$$\sum_{L \subseteq A} m(L) \leq \sum_{K \subseteq B} m(K) \quad \forall A \subset B \subseteq X \quad (28)$$

بعد از این که مقاله با استفاده از معادلات اثبات می‌کند که با استفاده از انتگرال چوکت مساله‌ی یادگیری ارجحیت‌فازی به یک مساله‌ی بهینه‌سازی تبدیل می‌شود، توضیحی در مورد الگوریتم بهینه‌سازی مورد استفاده در آزمایشات خود نداده است.

۴ آزمایشات

۱.۴ داده‌ها

در این مقاله ۱۵ عدد دیتاست برای آزمایشات مورد استفاده قرار گرفته‌اند که اکثر آن‌ها از UCI و از چارچوب WEKA جمع آوری شده‌اند. که همگی آن‌ها معیارهای سنجش γ برای آزمودن الگوریتم‌های یادگیری می‌باشند. علاوه بر این‌ها، مقاله تعدادی مجموعه داده از دنیای واقعی، از منابع دیگر مانند داده‌هایی از یک فرآیند پلی‌استر صنعتی رنگرزی و اطلاعات در مورد ارزیابی مجلات ریاضی جمع آوری کرده است. جدول ۲ خلاصه‌ای از تمام مجموعه داده‌ها را نشان می‌دهد که در سایت نویسندگان γ مقاله در دسترس عموم گذاشته‌اند.

که مقدار $f_o(x_i)$ مقدار ارزیابی شده شی o براساس معیار x_i می‌باشد. رتبه‌ی شی o را می‌توان با استفاده از انتگرال چوکت که در ۱۷ و ۱۸ معرفی شد به صورت زیر می‌تواند باشد.

$$U(o) = C_\mu(f_o) \quad (22)$$

حال فرض کنیم داده‌های آموزشی به صورت مجموعه‌ای از اشیا (بردارای از ویژگی‌های منتصب به هر شی) به همراه برچسب l_i هر کدام از داده‌ها می‌باشد، $i = 1, \dots, N$ ، از این داده‌ها یک داده‌ی جدید مانند \mathcal{D} استخراج می‌شود که رابطه‌ی ارجحیت اشیا داخل دیتاست اولیه را به صورت دودویی مدل می‌کند به‌طوری که، $(o_i, o_j) \in \mathcal{D}$ که نشان می‌دهد که $o_i \succ o_j$ به شرطی که اگر در دیتاست اولیه داشته باشیم (o_i, l_i) و (o_j, l_j) به‌طوری که $l_i > l_j$. در راستای ایده‌ی به حداقل رساندن ریسک بصورت تجربی γ ، مقاله سعی کرده تعداد خطاهای رتبه‌بندی را با استفاده از انتگرال چوکت بر روی مجموعه داده آموزشی \mathcal{D} به حداقل برساند. از آن جایی که انتگرال چوکت منحصرًا توسط معیار μ بر روی مجموعه $X = \{x_1, \dots, x_n\}$ مشخص می‌شود، بنابراین تعریف مناسب این معیار اهمیت زیادی دارد - که به همین علت بود که از نگاشت موبیوس در ۱۷ استفاده کرده است.

مقاله با الهام از اصل حداکثر حاشیه γ در روش‌های مبتنی بر کرنل γ یادگیری ماشین مساله‌ی یادگیری μ را به عنوان یک مساله‌ی بهینه‌سازی مدل کرده است.

$$\max_{M, \xi_1, \dots, \xi_r} \left\{ M - \frac{\gamma}{|\mathcal{D}|} \sum_{(o_s, o_t) \in \mathcal{D}} \xi_s + \xi_t \right\} \quad (23)$$

به‌طوری که دارای شروط تعریف شده از ۲۴ تا ۲۸ می‌باشد. که مقدار M نشان دهنده‌ی حاشیه‌ای است که می‌خواهیم حداکثرش کند - که می‌شود حداقل اختلاف میان میزان سودمندی دو شی که مانند o_s و o_t می‌باشد به‌گونه‌ای که $o_s \succ o_t$. به‌طور خاص‌تر اگر بخواهیم بگوییم M یک حاشیه‌ی نرم است که با احتساب این حقیقت که در حالت کلی ارضای تمام نابرابری‌ها به طور هم‌زمان

^{۳۰} Slack

^{۳۱} Trade-Off

^{۳۲} Bench-mark

^{۳۳} <http://www.uni-marburg.de/fb12/kebi/research>

^{۲۷} Empirical Risk Minimization

^{۲۸} Maximum Margin Principle

^{۲۹} Kernel-Based

data set	#instances	#attributes	#classes	source
Color(CLR) 1-7	120	3	3	[5]
Scientific Journals(SCJ)	172	5	4	[6]
CPU	209	6	2	UCI
Auto MPG	398	8	6	UCI
Employee Selection(ESL)	488	4	9	WEKA
Mamographic(MMG)	830	5	2	UCI
Lecture Evaluation(LEV)	1000	4	5	WEKA
Concrete Compressive Strength(CCS)	1030	8	6	UCI
Car Evaluation(CEV)	1728	6	4	UCI

جدول ۲: دیتاست‌ها و ویژگی‌های آن‌ها

در ادامه، شرح مختصری در مورد ۲ دیتاست از مجموعه ۲.۴ مقایسه داده‌های جدول ۲ آورده شده است.

مقاله روش ارائه شده‌ی خود را برای رتبه‌بندی با کرنل های خطی و چندجمله‌ای روش RankSVM که یکی روش‌های مدرن ۲۵ برای مساله رتبه‌بندی می‌باشد مقایسه کرده است. که نتیجه‌ی این مقایسه‌ها در جدول ۳ آمده است. در این جدول که میزان دقت (همراه با انحراف معیار چندین اجرا) ۳ الگوریتم میانگین وزنی ۳۶ و RankSVM با ۳ درجه‌ی چندجمله‌ای کرنل و روش ارائه شده در مقاله (CI^{۳۷}) آورده شده است. در کنار هرکدام از دقت ها عددی که داخل پرانتز آورده شده است رتبه‌ی دقت الگوریتم مربوطه در آن دیتاست را نمایش می‌دهد و در سطر آخر نیز میانگین رتبه‌ی هرکدام از الگوریتم‌ها آورده شده است. همان‌طور که آورده شده است روش ارائه شده با بیشترین میانگین دقت نتایج مطلوب تری را بدست داده است.

برای ملموس‌تر شدن نتایج بدست آمده در جدول ۳ جدول ۸ را که به‌نوعی ماتریس درهم‌ریختگی رتبه‌ی روش‌ها در اجرا بر روی دیتاست‌های مختلف ارائه شده است که درک بهتری نسبت به اینکه روش ارائه شده در مقاله دیگر روش‌های مدرن در این زمینه را مغلوب کرده است.

۱.۱.۴ دیتاست CPU: این یک مجموعه‌ی داده، معیار سنجش استاندارد از مخزن UCI است. که در رابطه با عملکرد نسبی CPU‌های می‌باشد که شامل ۱۰ عدد ویژگی، که سه تا از آن آنجایی که به وضوح فاقد ارزش پیش‌گویی بوده اند حذف شده‌اند (نام‌فروشنده، نام‌مدل، EPR^{۳۴}). که مشخصات ویژگی‌های مورد استفاده از این دیتاست در جدول ۴ آمده است. در جدول ۵ نیز چند سطر از داده‌های این دیتاست آمده است که در این دیتاست برچسب (ویژگی PRP) دارای مقداری پیوسته می‌باشد.

۲.۱.۴ دیتاست Mamographic: این مجموعه‌ی داده، دارای اطلاعاتی در مورد سرطان پستان توسط که ماموگرافی بدست آمده است. هدف پیش‌بینی شدت (خوش‌خیم یا بدخیم) توده با استفاده از ویژگی‌های BI-RADS می‌باشد. این دیتاست دارای ۶ عدد ویژگی بوده که از این ۶ عدد ویژگی یکی از آن‌ها ویژگی هدف (خوش‌خیم یا بدخیم می‌باشد) و یکی از ویژگی‌ها قابل پیش‌بینی نمی‌باشد و دارای ۴ ویژگی دیگر که قابل پیش‌بینی می‌باشند. که مشخصات ویژگی‌های مورد استفاده از این دیتاست در جدول ۶ آمده است. در جدول ۷ نیز چند سطر از داده‌های این دیتاست آمده است.

^{۳۵} State of the art

^{۳۶} Weighted Mean

^{۳۷} Choquet Integral

^{۳۴} Estimated Relative Performance

data set	WM	PL d=1	PL d=2	PL d=3	CI
CLR 1	.9663±.0148(4)	.9506±.0155(5)	.9674±.0129(3)	.9700±.0141(2)	.9828±.0090(1)
CLR 2	.8740±.0293(4)	.8601±.0294(5)	.8876±.0200(3)	.9341±.0244(2)	.9804±.0128(1)
CLR 3	.9343±.0204(4)	.9268±.0219(5)	.9375±.0156(3)	.9633±.0143(2)	.9878±.0150(1)
CLR 4	.9357±.0171(4)	.9228±.0247(5)	.9431±.0189(3)	.9659±.0166(2)	.9915±.0056(1)
CLR 5	.9518±.0194(3)	.9485±.0179(5)	.9565±.0142(2)	.9516±.0171(4)	.9682±.0140(1)
CLR 6	.9046±.0202(4)	.8923±.0205(5)	.9127±.0201(3)	.9460±.0191(2)	.9825±.0121(1)
CLR 7	.8880±.0312(4)	.8797±.0256(5)	.8892±.0219(3)	.9258±.0237(2)	.9688±.0167(1)
SCJ	.8168±.0105(4)	.8098±.0112(5)	.8270±.0241(3)	.8313±.0109(2)	.8450±.0201(1)
CPU	.9965±.0027(3)	.9950±.0093(5)	.9978±.0012(2)	.9955±.0005(4)	.9986±.0014(1)
MPG	.8887±.0176(4)	.8850±.0143(5)	.8912±.0078(3)	.8967±.0093(2)	.9060±.0111(1)
ESL	.9497±.0162(2)	.9559±.0071(1)	.9465±.0104(4)	.9491±.0126(3)	.9424±.0098(5)
MMG	.8961±.0230(2)	.8536±.0168(4)	.8714±.0181(3)	.7813±.0350(5)	.9015±.0210(1)
LEV	.8710±.0289(2)	.8620±.0320(3)	.8713±.0250(1)	.8527±.0300(5)	.8610±.0320(4)
CCS	.8650±.0068(4)	.8586±.0102(5)	.8862±.0184(3)	.8962±.0203(2)	.9050±.0038(1)
CEV	.8981±.0066(4)	.8804±.0076(5)	.9118±.0059(3)	.9585±.0090(2)	.9771±.0039(1)
average rank	3.47	4.53	2.8	2.73	1.47

جدول ۳: مقایسه‌ی دقت روش‌های متفاوت با روش RankSVM با کرنل‌های درجات ۱ تا ۳ و همچنین روش معمول میانگین وزنی

این مقاله نشان داده است که با بکارگیری انتگرال چوکت و نگاشت موبیوس مساله‌ی یادگیری ارجحیت فازی به یک مساله‌ی بهینه‌سازی تبدیل می‌شود که می‌توان با هر الگوریتم بهینه‌سازی اقدام به حل این مساله کرد.^{۳۸} در نهایت با مقایسه‌ای که با مدرن ترین الگوریتم‌های موجود در این زمینه نشان داده است که این روش بهتر از بقیه نتیجه داده است.

	WM	PL d=1	PL d=2	PL d=3	CI
WM	–	14	2	5	2
PL d=1	1	–	1	3	2
PL d=2	13	14	–	4	2
PL d=3	10	12	11	–	1
CI	13	13	13	14	–

جدول ۸: ماتریس درهم‌ریختگی رتبه‌ی روش‌ها در اجرا بر روی دیتاست‌های مختلف ارائه شده در جدول ۲

همان‌طور که در جدول ۸ مشاهده می‌شود از ۱۵ دیتاست مورد استفاده در آزمایشات مقاله روش ارائه شده دارای بیشترین امتیاز برد نسبت به سایر الگوریتم‌ها مورد مقایسه می‌باشد که الگوریتم‌های مورد مقایسه از روش‌های مدرن در این زمینه می‌باشد.

مراجع

- [1] A. F. Tehrani, W. Cheng, and E. Hullermeier, "Preference Learning Using the Choquet Integral: The Case of Multipartite Ranking". in Fuzzy Systems. IEEE Transactions, Dec. 2012, vol. 20, pp. 1102–1113.
- [2] J. Furnkranz and E. Hullermeier, "Encyclopedia of Machine Learning". Springer, 2010, ch. Preference Learning, pp. 789–795.
- [3] M. Safayani, "Fuzzy integral lecture". In "Fuzzy Set and Systems' Course", Isfahan University Of Technology, Spring 2015.
- [4] J. Furnkranz and E. Hullermeier, "Preference Learning". Kunstliche Intelligenz, pp. 60–61, 2005.
- [5] M. Nasiri and S. Berlik, "Modeling of polyester dyeing using an evolutionary fuzzy system". in Proc. Joint Int. Fuzzy Syst. Assoc. World Congr. Eur. Soc. Fuzzy Logic Technol. Conf., 2009, pp. 1246–1251.
- [6] G. Beliakov and S. James, "Citation-based journal ranks: The use of fuzzy measures". Fuzzy Sets Syst., vol. 167, no. 1, pp. 101–119, 2011.

^{۳۸} البته مقاله در مورد الگوریتم بهینه‌سازی اعمال شده برای مدل ارائه شده در مقاله سخنی نگفته است.

۵ نتیجه‌گیری

در این مقاله کاربرد انتگرال چوکت را در مسائل یادگیری ارجحیت ارائه داده است. درواقع از انتگرال چوکت به عنوان تابع سودمندی برای مسائل رتبه‌بندی استفاده کرده است، که این انتگرال را بخاطر یک سری ویژگی‌های منحصر به فرد انتگرال چوکت که پیشتر آورده شده است انتخاب شده است؛ که مهم‌ترین این ویژگی‌ها این بود که این انتگرال می‌تواند ارتباط وابستگی ارزشی بین معیارها را که به طور ذاتی دارای خاصیت غیرافزایشی می‌باشند، به‌خوبی نشان دهد.

Feature	Description	Data Type
MYCT	Machine cycle time in nanoseconds	Integer
MMIN	Minimum main memory in kilobytes	Integer
MMAX	Maximum main memory in kilobytes	Integer
CACH	Cache memory in kilobytes	Integer
CHMIN	Minimum channels in units	Integer
CHMAX	Maximum channels in units	Integer
PRP	Published relative performance(class)	Integer

جدول ۴: ویژگی‌های مورد استفاده‌ی دیتاست CPU

Row#	MYCT	MMIN	MMAX	CACH	CHMIN	CHMAX	PRP(Class)
1	125	256	6000	256	16	128	198
2	29	8000	32000	32	8	32	269
3	29	8000	32000	32	8	32	220
4	29	8000	32000	32	8	32	172

جدول ۵: چند مثال از دیتاست CPU

Feature	Description	Data Type
BI-RADS	Assessment, (non-predictive!)	Ordinal
Age	Patient's age in years	Integer
Shape	Mass shape	Nominal
Margin	Mass margin	Nominal
Density	Mass density	Ordinal
Severity	Intensity(class)	Binominal

جدول ۶: ویژگی‌های مورد استفاده‌ی دیتاست Mamographic

Row#	BI-RADS	Age	Shape	Margin	Density	Severity(class)
1	5	67	3	5	3	1
2	4	43	1	1	?	1
3	5	58	4	5	3	1
4	4	28	1	1	3	0

جدول ۷: چند مثال از دیتاست Mamographic