

# یادگیری ارجحیت با استفاده از شبکه‌های عصبی مصنوعی

داریوش حسن‌پور آده<sup>۱</sup>

<sup>۱</sup> دانشگاه صنعتی اصفهان، دانشکده مهندسی برق و کامپیوتر، شماره دانشجویی: ۹۳۰۸۱۶۴

## چکیده

یادگیری ارجحیت یکی از زیررشته‌های یادگیری ماشین می‌باشد که هدف اصلی‌اش یادگیری ارجحیت‌های قابل پیش‌بینی از روی اطلاعات ارجحیت می‌باشد. از نقطه‌نظر یادگیری باناظر یادگیری ارجحیت روی یک دسته از عناصر که نسبت به یک دسته از برجسب‌ها یا عناصر ارجحیت بیشتری دارند آموزش داده می‌شوند که بتواند در نهایت مدل ارجحیت عناصر دیده نشده را پیش‌بینی کند. در این گزارش با تکیه بر مطالب مقاله‌ای اصلی به معرفی یک روش یادگیری جهت یادگیری رتبه‌بندی<sup>۱</sup> می‌پردازیم که توسط شبکه‌ای به نام CmpNN به رتبه‌بندی میان اشیاء می‌پردازد. شبکه‌ی معرفی شده دارای معماری خاصی بوده و الگوریتمی که معرفی شده به نحو خاصی آموزش داده می‌شود تا بهترین توصیف آموزشی متناسب با وزن‌های شبکه و داده‌های آموزشی را مشاهده کند. همچنین در کنار شرح مقاله‌ای اصلی به مروری بر دیگر کارهای انجام شده در زمینه‌ی یادگیری ارجحیت با شبکه‌های عصبی مصنوعی خواهیم پرداخت.

## کلمات کلیدی

یادگیری ارجحیت، شبکه‌های عصبی مصنوعی، شبکه‌ی ارجحیت، یادگیری انتخابی، طبقه‌بندی

## ۱ مقدمه

در این نوشتار ابتدا مقدمه‌ای بر مفاهیم بنیادی مطرح در یادگیری ارجحیت آورده شده است و بعد از مروری خلاصه بر تعدادی از کارهای انجام شده در این زمینه، با تمرکز بر مقاله اصلی یادگیری ارجحیت با استفاده از ANN را ارائه خواهیم داد.

## ۲ یادگیری ارجحیت

برای اینکه بتوانیم یادگیری ارجحیت با استفاده از شبکه‌های عصبی مصنوعی را ارائه دهیم نیاز هست که در این قسمت به معرفی خلاصه‌ای از مفاهیم اولیه و بنیادی زمینه‌ی یادگیری ارجحیت بپردازیم.

### ۱-۲ نمادگذاری

طبق هر شاخه‌ی علمی دیگر به یک سری نماد برای پایه‌گذاری یادگیری ارجحیت نیاز داریم که در این قسمت به معرفی آن‌ها می‌پردازیم.

**تعریف ۱** (ارجحیت ضعیف). یک ارجحیت ضعیف با نماد  $\succeq$  بروی مجموعه‌ای مانند  $A$  یک رابطه‌ی بازتابی و تعددی می‌باشد.

**تعریف ۲** (ارجحیت اکید).  $a \succ b \leftrightarrow (a \succeq b) \wedge (b \not\succeq a)$ .

در راستای معناشناسی یادگیری ارجحیت تعاریف ۱ و ۲ می‌توان آن‌ها را به صورت جدول ۱ تعبیر کرد.

یادگیری ارجحیت<sup>۲</sup> یکی از شاخه‌های یادگیری ماشین<sup>۳</sup> می‌باشد که در سال‌های اخیر توجه زیادی را به سمت خود جلب کرده است. وظیفه‌ی اصلی یادگیری ارجحیت، یادگیری رتبه‌بندی کردن عناصر می‌باشد. که با توجه به نوع اطلاعات آموزشی نوع ارجحیت و همچنین نوع رتبه‌بندی می‌تواند تغییر کند. در حالت کلی یادگیری ارجحیت به استنتاج کردن ارتباطات بین اعضای یک دسته و نگاشت این ارتباطات به مدلی که بتواند ارجحیت نسبی موجود بین اعضای این دسته بخوبی پیش‌بینی کند.

اگر بخواهیم تعریف دقیقی برای یادگیری ارجحیت ارائه دهیم می‌توانیم بگوییم که یادگیری ارجحیت به وظیفه‌ی یادگیری پیش‌بینی کردن رابطه‌ی ترتیب<sup>۴</sup> در مجموعه‌ای از اشیاء گفت [۴]. یادگیری ارجحیت از داده‌های اطلاعات ارجحیت<sup>۵</sup> برای اهداف یادگیری خود استفاده می‌کند که این اطلاعات ارجحیت نقش مهمی در تصمیم‌گیری‌های خودکار در زمینه‌های متعددی مانند تئوری تصمیم‌گیری‌های کیفی<sup>۶</sup>، استدلال غیریکنواخت<sup>۷</sup>، رضای محدودیت<sup>۸</sup> و طرح‌ریزی<sup>۹</sup> و ... کاربردهای فراوانی دارد. در مرحله‌ی آموزش، الگوریتم‌های یادگیری ارجحیت به داده‌های ترتیب رتبه‌بندی<sup>۱۰</sup> (نیمه) شناخته شده عناصر دسترسی دارند. بسته به مدل و نوع مساله الگوریتم‌های یادگیری ارجحیت می‌توانند به ۳ دسته‌ی رتبه‌بندی اشیاء<sup>۱۱</sup>، رتبه‌بندی برجسب‌ها<sup>۱۲</sup> و رتبه‌بندی نمونه‌ها<sup>۱۳</sup> تقسیم‌بندی کرد.

| نماد          | تعبیر  |
|---------------|--|
| $a \succeq b$ | "جایگزین $a$ حداقل به اندازه‌ی جایگزین $b$ ترجیح داده می‌شود." |
| $a \succ b$   | "جایگزین $a$ بیشتر از جایگزین $b$ ترجیح داده می‌شود."          |

جدول ۱: تعبیر نمادهای روابط ارجحیت

ها نمایش داده می‌شود. سپس یک سری برچسب و همچنین به ازای هر کدام از نمونه‌ها یک مجموعه‌ی دوبه‌دو مرتب که ارجحیت برچسب‌ها برای هر کدام از نمونه‌ها مشخص شده است را به عنوان ورودی به الگوریتم داده می‌شود. الگوریتم‌های متعلق به رتبه‌بندی برچسب‌ها باید به عنوان خروجی یک تابع رتبه‌بند است که بتواند به ازای یک شی جایگشت‌های برچسب‌های متعلق به آن شی را با توجه به ارجحیتی که دارند برگرداند.

## ۲-۲-۲ رتبه‌بندی اشیا

در این رتبه‌بندی هدف این است که یک دسته از اشیا را برحسب ارجحیتی که نسبت به هم دارند، را مرتب‌سازی کنیم. که شماتیک ورودی‌ها و خروجی‌ها این نوع الگوریتم در شکل ۲ آمده است.

Given:

- A (potentially infinite) set  $\mathcal{X}$  of objects (each object typically represented by a feature vector)
- A finite set of pairwise preferences  $x_i \succ x_j, (x_i, x_j) \in \mathcal{X} \times \mathcal{X}$

Find:

- A ranking function  $r(\cdot)$  that, given a set of objects  $\mathcal{O} \subseteq \mathcal{X}$  as input, returns a permutation (ranking) of these objects

شکل ۲: شماتیک کلی الگوریتم‌های رتبه‌بندی اشیا

در شماتیکی که در شکل ۲ آمده است می‌بینیم که همانند رتبه‌بندی برچسب‌ها یک دسته از اشیا را به عنوان ورودی می‌گیرد. سپس یک دسته‌ی (تکه‌ای) مرتب از ارجحیت‌های نسبی این اشیا را نیز به عنوان ورودی به الگوریتم می‌دهیم و نهایت الگوریتم باید یک تابع رتبه‌بند را بیابد که بتواند ارجحیت‌های هر زیرمجموعه از مجموعه‌ی جهانی اشیا را در قالب یک جایگشتی از اشیا ورودی به عنوان خروجی برگرداند.

توجه شود که مجموعه‌ی (تکه‌ای) مرتب از ارجحیت اشیا که به عنوان داده آموزشی به الگوریتم داده می‌شود نیازی ندارد که تمامی ارجحیت‌های موجود میان اشیا را شامل باشد، به چند دلیل این شرط می‌تواند به قابل پیاده‌سازی بودن الگوریتم کمک زیادی کند. اولین دلیل که بدیهی‌ترین دلیل می‌باشد، این است که ممکن است در کاربردهای دنیای واقعی این الگوریتم تمامی ارجحیت‌های موجود بین اشیا نشاخته نشده باشد. دومین دلیل این است که در صورتی که تمامی ارجحیت‌های بین اشیا شناخته شده باشد اندازه‌ی مجموعه‌ی مرتب از ارجحیت خیلی بیشتر از تعداد اشیا می‌باشد؛ که از حل ۱ می‌بینیم این افزونگی داده‌ای تقریباً  $\frac{n}{2}$  برابر تعداد اشیا می‌باشد که در کاربردهای واقعی این الگوریتم‌ها معمولاً تعداد اشیا زیاد است که در نتیجه تعداد ارتباطات مرتب بین آنها بسیار بیشتر از تعداد اشیا می‌باشد که مشکلات خواص خودش را در پی دارد که خارج از حیطه‌ی این نوشتار است.

$$\frac{\binom{n}{2}}{n} = \frac{n-1}{2} \quad (۱)$$

در نتیجه این شرط که الگوریتم‌های رتبه‌بندی اشیا تنها با در اختیار داشتن مجموعه‌ی تکه‌ای مرتب از ارجحیت‌های میان اشیا باید بتواند مدلی برای رتبه‌بندی اشیا بدست بیاورد؛ باعث می‌شود که این الگوریتم‌های در کاربردهای دنیای واقعی کاربرد

**تعریف ۳** (ترتیب‌اکید کلی<sup>۱۴</sup> - رتبه‌بندی<sup>۱۵</sup>). اگر  $\mathcal{A}$  یک مجموعه‌ای از اشیا / جایگزین‌ها<sup>۱۶</sup>  $\{a_1, \dots, a_m\}$  باشد، یک رتبه‌بندی از  $\mathcal{A}$  یک جایگشتی همانند  $\tau$  از مجموعه‌ی  $\{1, \dots, m\}$  می‌باشد بگونه‌ای که  $a_i \succ a_j \leftrightarrow \tau(i) < \tau(j)$

در تعریف ۳ مقدار  $m$  تعداد اشیا/جایگزین‌ها و  $a_i$  همان اشیا/جایگزین‌ها می‌باشند، که از این به بعد به مجموعه‌ی اشیا یا جایگزین‌ها، فقط جایگزین گفته خواهد شد. تعریف ۳ در واقع فرمت<sup>۱۷</sup> خروجی کلی الگوریتم‌های یادگیری ارجحیت را ارائه می‌دهد، به گونه‌ای که خروجی ارجحیت ورودی‌ها یک جایگشتی اندیسی<sup>۱۸</sup> ترتیب‌اکید ارجحیت‌های ورودی‌ها می‌باشد بگونه‌ای که **اندیس** آن جایگزینی که دارای ارجحیت بیشتری نسبت به دیگری است، در مجموعه‌ی  $\tau$  **مقدم‌تر** از دیگری می‌آید.

طبق آنچه که در تعریف ۳ آمده، واضح است که الگوریتم‌های یادگیری ارجحیت درواقع یک جستجوکننده در فضای جایگشتی مجموعه  $\tau$  می‌باشد؛ فضای جایگشت‌های  $\tau$  را با  $\mathcal{S}_m$  نمایش می‌دهند.

## ۲-۲ انواع الگوریتم‌های رتبه‌بندی

الگوریتم‌های رتبه‌بندی از نظر نوع وظیفه‌ای که به عهده دارند به ۳ تیپ تقسیم بندی می‌شوند که عبارتند از رتبه‌بندی برچسب‌ها، رتبه‌بندی اشیا و رتبه‌بندی نمونه‌ها؛ که در این قسمت شرح مختصری از این ۳ تیپ الگوریتم ارائه خواهیم داد[۴].

### ۱-۲-۲ رتبه‌بندی برچسب‌ها

در این رتبه‌بندی هدف این است که به ازای یک نمونه برچسب‌ها را براساس ارجحیت مرتب کند. شماتیک ورودی‌ها و خروجی‌ها این نوع الگوریتم در شکل ۱ آمده است.

Given:

- A set of training instances  $\{x_k | k=1, \dots, n\} \subseteq \mathcal{X}$  (each instance typically represented by a feature vector)
- A set of labels  $\mathcal{L} = \{\lambda_i | i=1, \dots, m\}$
- For each training instance  $x_k$ : a set of associated pairwise preferences of the form  $\lambda_i \succ_{x_k} \lambda_j$

Find:

- A ranking function in the form of an  $\mathcal{X} \rightarrow \mathcal{S}_m$  mapping that assigns a ranking (permutation)  $\succ_x$  of  $\mathcal{L}$  to every  $x \in \mathcal{X}$

شکل ۱: شماتیک کلی الگوریتم‌های رتبه‌بندی برچسب‌ها

همانطور که در شکل ۱ آمده است الگوریتم‌های رتبه‌بندی برچسب‌ها تعدادی نمونه‌ی آموزشی می‌گیرد که این نمونه‌های آموزشی معمولاً به صورت بردار ویژگی

پیدا کند.

صورت تعریف ۳ با استفاده از رتبه‌بند ارجحیت مدل کرد.

## ۳-۲-۲ رتبه‌بندی نمونه

رتبه‌بندی نمونه همانند رتبه‌بندی اشیا می‌باشد یعنی علاوه بر شماتیک معرفی شده در رتبه‌بندی اشیا ۲ عدد ورودی دیگر را نیز دارد. به این صورت که یک مجموعه اکیدا مرتب (تعریف ۲ را ببینید) از برچسب‌ها را نیز اختیار می‌کند که در این مجموعه مرتب از برچسب‌ها آن برچسبی که دارای ارجحیت بیشتری است در ابتدای مجموعه ظاهر شود. و همچنین یک ورودی دیگر نیز به الگوریتم داده می‌شود که مجموعه ارتباطات یک‌به‌یک از هر کدام از اشیا را به برچسب متعلق به آن شی می‌باشد. همچنین در این نوع از الگوریتم‌ها نیازی به مجموعه (تکه‌ای) مرتب از ارجحیت‌های نسبی اشیا به الگوریتم داده شود.

## ۳-۲-۳ موارد خاص یادگیری ارجحیت

همان‌طور که در قسمت ۲-۲ آمده است الگوریتم‌های یادگیری ارجحیت از نظر اهداف و کاربرد با یک‌دیگر متفاوت هستند، ما همه روزه در میان الگوریتم‌های طبقه‌بندی روزمره‌ای که با آنها سروکار داریم در واقع داریم از الگوریتم‌های ارجحیت استفاده می‌کنیم که در اینجا به معرفی دو نوع از الگوریتم‌های طبقه‌بندی می‌پردازیم که حالت خاصی از الگوریتم‌های یادگیری ارجحیت می‌باشند.

## ۱-۳-۲ طبقه‌بندی

الگوریتم‌های طبقه‌بند<sup>۱۹</sup> که همه روزه از آنها استفاده می‌کنیم در واقع حالت خاصی از الگوریتم‌های رتبه‌بندی برچسب‌ها می‌باشد. از آنجایی که در طبقه‌بندی به ازای یک ورودی هدف پیش‌بینی برچسب مرتبط با آن ورودی می‌باشد، می‌توان داده‌ی ورودی را به یکی از الگوریتم‌های یادگیری ارجحیت (رتبه‌بندی برچسب‌ها) داد سپس از میان مجموعه جایگزین برچسب‌ها که به عنوان خروجی رتبه‌بند برگشت داده خواهد شد، آن برچسبی را که دارای بیشترین ارجحیت است را به عنوان برچسب منتخب برای آن نمونه ورودی انتصاب کرد. به عبارت دیگر می‌توان با استفاده از تعریف ۲ الگوریتم‌های طبقه‌بند را با استفاده از رتبه‌بند برچسب‌های یادگیری ارجحیت مدل کرد.

$$C_{x_k} = \{\lambda_i \mid \lambda_i \succ_{x_k} \lambda_j, 1 \leq j \neq i \leq m\} \quad (۲)$$

## ۲-۳-۲ طبقه‌بندی چند برچسب

در طبقه‌بندی چند برچسب<sup>۲۰</sup> هر نمونه به یک زیرمجموعه‌ای از برچسب‌ها نسبت داده می‌شود. این نوع از الگوریتم‌ها را نیز حالت خاصی از الگوریتم‌های یادگیری ارجحیت (رتبه‌بندی برچسب‌ها) می‌باشد به گونه‌ای که الگوریتم رتبه‌بندی برچسب‌ها یک عدد به عنوان تعداد برچسب‌های نسبت داده شده به اشیا داده می‌شود و الگوریتم بعد از مرتب‌سازی برچسب‌ها بر اساس ارجحیت‌هایی که دارند یک تعداد از برچسب‌ها که دارای ارجحیت بیشتری می‌باشند را به عنوان خروجی بر می‌گرداند. یا یک روش دیگر برای مدل کردن طبقه‌بند چند برچسب با استفاده از رتبه‌بند برچسب‌ها این است که در کنار داده‌های الگوریتم یک حد آستانه مابین  $[0, 1]$  به الگوریتم داده شود و بعد از رتبه‌بندی برچسب‌ها و نرمال‌سازی میزان ارجحیت‌های برچسب‌ها آن برچسب‌هایی که میزان ارجحیت آنها بیشتر از حد آستانه به عنوان خروجی برگشت داده شود. در حالت کلی می‌توان طبقه‌بند چند برچسب را به

$$C_{x_k} = \{\mathcal{L}_k \mid \lambda_i \succ_{x_k} \lambda_j, \lambda_i \in \mathcal{L}_k, \lambda_j \in \mathcal{L} \setminus \mathcal{L}_k\} \quad (۳)$$

## ۴-۲ انواع روش‌های یادگیری ارجحیت

برای یادگیری ارجحیت دو روش معمول موجود است که یکی بر اساس یادگیری یک تابع سودمندی<sup>۲۱</sup> و دیگری یادگیری ارتباطات ارجحیت<sup>۲۲</sup> موجود بین داده‌ها را یاد می‌گیرد که برای درک بهتر روش ارائه شده در مقاله اصلی در این بخش به توضیح مختصری نسبت به هریک می‌پردازیم.

## ۱-۴-۲ یادگیری تابع سودمندی

یک راه طبیعی برای نشان دادن ارجحیت‌های موجود بین داده‌ها این است که جایگزین‌های موجود را با استفاده از یک تابع مطلوبیت ارزیابی کنیم. برای رتبه‌بندی اشیا یک تابع نگاشت  $f: \mathcal{X} \rightarrow \mathcal{U}$  که مقدار سودمندی  $f(x)$  به هریک از اشیا  $x$  تخصیص می‌دهد را یاد می‌گیریم و در نهایت اشیا را با معیار سودمندی‌ای که از این تابع سودمندی یادگرفته شده محاسبه می‌شود مرتب کرده و به عنوان خروجی بر می‌گردانیم. و در رتبه‌بندی برچسب‌ها به ازای هریک از برچسب‌ها  $\lambda_i, i = 1, \dots, m$  یک تابع سودمندی  $f_i: \mathcal{X} \rightarrow \mathcal{U}$  یادگرفته می‌شود و در نهایت برچسب‌ها را برحسب مقدار سودمندی‌ای که آن برچسب‌ها دارند مرتب می‌کنیم،  $\lambda_i \succ_x \lambda_j \Rightarrow f_i(x) \geq f_j(x)$

## ۵-۲ یادگیری ارتباطات ارجحیت

یک روش معمول دیگر در یادگیری ارجحیت این است که بیاییم و ارتباطات ارجحیت دودویی موجود بین دو اشیا (برچسب) ها را یاد بگیریم. برای رتبه‌بندی اشیا یک تابع ارجحیت دودویی مانند  $Q(x, x')$  یاد می‌گیرد که نشان می‌دهد آیا شی  $x$  نسبت به  $x'$  ارجحیت دارد یا خیر. در نهایت ترتیب نهایی شامل یک جایگزینی می‌باشد که حداکثر سازگاری را با این ترتیب‌های دودویی داشته باشند. به عبارت دیگر جایگزینی را انتخاب می‌کنیم که مقدار ۴ را حداکثر کند.

$$V_{\mathcal{X}} = \sum_{i=1}^n \sum_{j \neq i=1}^n Q(x_i, x_j) \quad (۴)$$

برای رتبه‌بندی برچسب‌ها هم یک روشی به نام طبقه‌بندی دوبه‌دو ارائه شده است. ایده‌ی این طبقه‌بند دوبه‌دو این است که به ازای هریک از برچسب‌ها یک مدلی مانند  $\mathcal{M}_{i,j}, 1 \leq i < j \leq m, (\lambda_i, \lambda_j) \in \mathcal{L}$  را با استفاده از داده‌های آموزشی بدست بیاوریم (یاد بگیریم)؛ در نتیجه به تعداد  $\frac{m(m-1)}{2}$  تعداد مدل نیاز داریم. داده‌های آموزشی شامل اطلاعات ارجحیت برچسب‌ها مانند  $\lambda_i \succ_x \lambda_j$  می‌باشند که به صورت مثال‌های آموزشی  $(a, b)$  تبدیل می‌شوند که برای یادگیری مدل  $\mathcal{M}_{a,b}, a = \min(i, j), b = \max(i, j)$  استفاده می‌شوند. در واقع مدل  $\mathcal{M}_{a,b}$  سعی بر یادگیری مدلی دارد که نگاشت ۵ را انجام دهد.

$$\mathcal{M}_{a,b} \mapsto \begin{cases} 1 & \lambda_a \succ_x \lambda_b \\ 0 & \lambda_b \succ_x \lambda_a \end{cases} \quad (۵)$$

که این نگاشت می‌تواند توسط یکی از طبقه‌بند کننده‌های دودویی انجام گیرد.

### ۳ یادگیری ارجحیت با استفاده از شبکه‌های عصبی

در این قسمت به شرح یادگیری ارجحیت با استفاده از شبکه‌های عصبی مصنوعی می‌پردازیم، ابتدا به معرفی شبکه‌ای جهت مقایسه کردن دو نمونه و سپس الگوریتمی جهت آموزش این شبکه با استفاده از داده‌های آموزشی که بتواند بین نمونه‌های ارجحیت قائل شود می‌پردازیم و در نهایت به ارائه نتایج آزمایش‌ها پرداخته و با یک نتیجه‌گیری به این نوشتار خاتمه می‌بخشیم.

#### ۱-۳ شبکه‌ی CmpNN

همان‌طور که گفته شد جهت تعیین ارجحیت بین اشیا باید بتوان به روشی دو نمونه را نسبت به هم مقایسه کرد که یکی از روش‌های مقایسه یادگیری توابع ارزیابی می‌باشد، تابع ارزیابی که معرفی شده است یک شبکه‌ی عصبی انتشار-به-جلو<sup>۲۳</sup> دولایه می‌باشد که از معماری خاصی پیروی می‌کند. در این روش دو نمونه به صورت یک زوج مرتب آموزش داده به شبکه داده می‌شود و از خروجی میزان ارجحیت موجود بین این دو نمونه برگردانده می‌شود. در اینجا فرض بر این شده است که هر نمونه ورودی شبکه به تعداد  $d$  بعد دارند؛ بنابراین از آنجایی که هر دو نمونه جهت مقایسه به شبکه داده می‌شود، لذا شبکه باید دارای  $2d$  عدد ورودی باشد، همچنین یک لایه‌ی مخفی و ۲ خروجی برای شبکه در نظر گرفته شده است.

اگر فرض کنیم هر نمونه‌ی  $x$  موجود در دیتاست دارای  $d$  بعد داشته باشد:

$$\forall x \in \mathcal{D} \Rightarrow x : [x_1, \dots, x_d]^T$$

ورودی‌های شبکه‌ی معرفی شده به ازای دو نمونه از دیتاست جهت مقایسه به صورت زوج مرتب  $[x, y]$  نمایش داده می‌شود بطوری که:

$$[x, y]^T : [x_1, \dots, x_d, y_1, \dots, y_d]^T$$

و دو خروجی شبکه که به صورت  $N_{>}([x, y])$  و  $N_{<}([x, y])$  نمایش داده می‌شود، که تفسیر خروجی‌های شبکه به شرح زیر می‌باشد:

- $N_{>}([x, y])$  میزان نرخ ارجحیت  $x$  نسبت به  $y$  را نشان می‌دهد.
- $N_{<}([x, y])$  میزان نرخ ارجحیت  $y$  نسبت به  $x$  را نشان می‌دهد.

این شبکه‌ی عصبی می‌تواند توسط الگوریتم‌های معمول آموزش شبکه همانند الگوریتم انتشار-به-عقب آموزش داده شود. برای داده‌های آموزشی نیز به ازای هر جفت نمونه‌ای که ارجحیت آن‌ها را نسبت به هم می‌دانیم مقادیر هدف خروجی‌های شبکه را بصورت زیر مقدار دهی می‌کنیم:


$$t = [x, y] = \begin{cases} \begin{bmatrix} 1 & 0 \end{bmatrix}^T & x \succ y \\ \begin{bmatrix} 0 & 1 \end{bmatrix}^T & y \succ x \end{cases} \quad (۶)$$

و تابع خطا نیز توسط خطای مربعات خروجی‌ها محاسبه می‌شود:

$$E([x, y], t) = (t_1 - N_{>}([x, y]))^2 + (t_2 - N_{<}([x, y]))^2 \quad (۷)$$

که بعد از آموزش مدل، می‌توانیم از شبکه برای پیش‌بینی میزان ارجحیت بین دو نمونه استفاده کرد به گونه‌ای که:

$$\forall x, y \in \mathcal{D} : \begin{cases} x \succ y & N_{>}([x, y]) \geq N_{<}([x, y]) \\ y \succ x & N_{>}([x, y]) \leq N_{<}([x, y]) \end{cases} \quad (۸)$$



شکل ۳: شبکه‌ی معرفی شده‌ی CmpNN جهت مقایسه‌ی ارجحیت بین نمونه‌ها

یعنی اینکه اگر  $N_{>}([x, y]) \geq N_{<}([x, y])$  آن‌گاه  $x$  حداقل به اندازه‌ی  $y$  ارجحیت دارد و برعکس.

در یادگیری ارجحیت توابع ارزیابی که میزان ارجحیت بین نمونه‌ها را تعیین می‌کنند باید شامل خواص زیر باشند:

۱. بازتابی<sup>۲۴</sup>:  $\forall x \in \mathcal{D} \Rightarrow x \succeq x \ \& \ x \preceq x$ .
۲. هم‌ارزی بین  $>$  و  $<$ : اگر  $x \succ y$  آن‌گاه  $x \succ x$  و  $y \prec x$ .
۳. پادتقارن<sup>۲۵</sup>: اگر  $x \succ y$  و  $x \succ y$  آن‌گاه  $x = y$ .
۴. متعدی: اگر  $y \succ z$  و  $x \succ y$  آن‌گاه  $x \succ z$ .

روش ارائه شده خواص ۱ و ۲ را ارضا می‌کند ولی در شرایطی که  $N_{>}([x, y]) = N_{<}([x, y])$  و  $x \neq y$  خاصیت سوم را نمی‌تواند ارضا کند و همچنین ادعا کرده است که خاصیت چهارم را هیچ یک از روش‌های یادگیری ارجحیت نمی‌تواند گارانتی کند که همیشه می‌تواند ارضا کند (روش ارائه شده نیز نمی‌تواند این شرط را ارضا کند). با وجود اینکه خاصیت چهارم یک خاصیت مهمی می‌باشد که برای اینکه الگوریتم‌های یادگیری ارجحیت بتواند بخوبی بین نمونه‌ها ارجحیت قائل شوند باید دارا باشند ولی در از آن‌جایی که معمولاً توابع ارزیابی همچون CmpNN توسط یک الگوریتم مرتب‌سازی جهت مقایسه و سپس مرتب کردن نمونه‌ها مورد استفاده قرار می‌گیرد، در همه‌ی الگوریتم‌های مرتب‌سازی معمول خاصیت چهارم به‌صورت پیش‌فرض در نظر گرفته شده است. در نتیجه عدم ارضای این خاصیت چهارم در درست عمل کردن این شبکه‌ی ارزیابی برای رتبه‌دهی و ارجحیت‌بندی نمونه‌ها تأثیری نخواهد داشت (به شرط آن‌که روش مرتب‌سازی که این شبکه را به عنوان مقایسه‌کننده‌ی بین نمونه‌ای استفاده می‌کند خاصیت چهارم را به‌صورت پیش‌فرض در نظر داشته باشد).

شبکه‌ی CmpNN معرفی شده در شکل ۳ آمده است. شبکه‌های عصبی در حالت عمومی خواص ۱ و ۲ را نمی‌توانند ارضا کنند لذا در توضیح این روش آمده است که برای این‌که خواص ۱ و ۲ را بتوانند ارضا شوند باید از تکنیک اشتراک گذاری وزن‌ها استفاده شود. با توجه به نماد گذاری مقاله‌ی اصلی  $(v_{y_k, i}, v_{x_k, i})$  به معنی این است که یال متصل از ورودی  $x$  بعد  $k$ ام به نورون  $i$ ام لایه‌ی مخفی و  $(w_{i, <}, w_{i, >})$  یال متصل بین نورون  $i$ ام لایه‌ی مخفی به خروجی  $>$  شبکه می‌باشند (به شکل ۳ توجه کنید).

برای اشتراک گذاری وزن‌ها هر دو وزن در هر لایه وزن‌هایشان به اشتراک گذاشته می‌شوند. به این صورت که برای وزن‌های بین ورودی‌ها و لایه‌ی مخفی

را ارزیابی می‌کند؛ نتیجه‌ی این الگوریتم تکراری شبکه‌ای است که بهترین نتیجه را بر اساس معیار ارزیابی داشته باشد. در الگوریتم SortNet مجموعه‌های  $P_V^i$  و  $P_T^i$  شامل جفت نمونه‌هایی ارزیابی و آموزشی هستند که با آن‌ها شبکه‌ی عصبی را آموزش می‌دهیم. در ابتدا این مجموعه‌های تهی هستند ( $P_T^0$  و  $P_V^0$  - خطوط ۳ و ۴) و شبکه به صورت تصادفی وزن‌دهی می‌شوند (خط ۵) و در ابتدا به شبکه ی خام (آموزش ندیده) داده‌های آموزشی و تست را می‌دهیم و نمونه‌هایی که توسط شبکه درست و غلط ارجحیت‌بندی شده اند را بدست می‌آوریم (خطوط ۱۰ و ۱۱) سپس برای آن‌هایی که مجموعه‌ی تست درست ارجحیت‌بندی شده‌اند را به تابع ارزیاب کیفیت می‌دهیم و امتیاز ارجحیت‌بندی مجموعه را بدست می‌آوریم (خط ۱۲) و در صورتی که این امتیاز از بهترین بدست آمده تاکنون بیشتر باشد امتیاز و شبکه‌ی متناظر با آن را به عنوان شبکه‌ی برگزیده ذخیره می‌کنیم (خطوط ۱۳ تا ۱۶). سپس داده‌های خطا دار از مجموعه‌ی آموزشی و تست به ترتیب به داده‌هایی آموزشی و تستی که در دوره‌ی ۲۸ بعد که می‌خواهیم با آن‌ها شبکه را آموزشی دهیم و ارزیابی کنیم (خطوط ۷ تا ۹) اضافه می‌کنیم (خطوط ۱۷ و ۱۸) و در صورتی که شبکه خطایی نداشته باشد بهترین شبکه‌ی بدست آمده تاکنون را به عنوان خروجی برمی‌گردانیم (خطوط ۱۹ تا ۲۱). در صورتی که به حداکثر تعداد دوره رسیدیم بهترین شبکه‌ی بدست آمده را به عنوان خروجی برمی‌گردانیم (خط ۲۳).

### ۳-۳ ارزیابی کیفیت رتبه‌بندی

در این مقاله ۳ تابع ارزیابی کیفیت رتبه‌بندی (Ranking Quality) را معرفی کرده است که به شرح زیر می‌باشند:

۱.  $P@n$ : این معیار به صورت میزان ارتباط  $n$  مستند<sup>۲۹</sup> اول که رتبه‌بندی به آن‌ها ارجحیت بالاتری داده است را مشخص می‌کند؛ که به صورت زیر تعریف می‌شود:

$$P@n = \frac{\text{results } n \text{ top in docs relevant}}{n} \quad (۹)$$

۲.  $MAP$ : به عنوان میانگین‌گیری بر روی معیار  $P@n$  می‌باشد:

$$AP_q = \frac{\sum_{n=1}^{N_q} P@n \cdot \text{rel}(n)}{N_q} \quad (۱۰)$$

که در این جا  $N_q$  تعداد مستندات موجود در پرس‌وجو  $q$  می‌باشد.  $\text{rel}(q)$  در زمانی که  $n$  امین مستند در مجموعه مرتبط با پرس‌وجو می‌باشد مقدار ۱ را اختیار می‌کند در غیر این صورت ۰ بر می‌گرداند.

۳.  $NDCG@n$ : به عنوان یک استخراج‌کننده‌ی صریح امتیازات رتبه‌ی بندی مجموعه مستندات معرفی شده است:

$$NDCG@n \equiv Z_n \left( (2^{r_1} - 1) + \sum_{j=2}^n \frac{2^{r_j} - 1}{\log(j)} \right) \quad (۱۱)$$

که در این جا  $r_j \geq 0$  میزان ارتباط مستند  $j$ ام با موضوع مورد پرس‌وجو می‌باشد (برای مستندات با ارتباط ضعیف این مقدار کوچک است) و  $Z_n$  یک فاکتور نرمال‌سازی می‌باشد بگونه‌ای که مقدار  $NDCG@n$  برای مرتب سازی ایده‌آل<sup>۳۱</sup> مقدار ۱ داشته باشد.

### ۴-۳ آزمایش‌ها

در آزمایشات از دیتاست‌هایی که توسط آزمایشگاه تحقیقاتی آسیا میکروسافت استفاده شده است که برای رتبه‌بندی و تعیین اولیت مستندات به ازای پرس‌وجوهای

#### Algorithm 1 SortNet learning algorithm

```

1:  $T \leftarrow \text{Set of training objects}$ 
2:  $V \leftarrow \text{Set of validation objects}$ 
3:  $P_T^0 \leftarrow \emptyset$ ;
4:  $P_V^0 \leftarrow \emptyset$ ;
5:  $C^0 \leftarrow \text{RandomWeightNetwork}()$ ;
6: for  $i = 0$  to  $\text{max\_iter}$  do
7:   if  $i \geq 1$  then
8:      $C^i \leftarrow \text{TrainAndValidate}(P_T^i, P_V^i)$ ;
9:   end if
10:   $[E_T^i, R_T^i] \leftarrow \text{Sort}(C^i, T)$ ;
11:   $[E_V^i, R_V^i] \leftarrow \text{Sort}(C^i, V)$ ;
12:   $\text{score} \leftarrow \text{RankQuality}(R_V^i)$ ;
13:  if  $\text{score} > \text{best\_score}$  then
14:     $\text{best\_score} \leftarrow \text{score}$ ;
15:     $C^* \leftarrow C^i$ ;
16:  end if
17:   $P_T^{i+1} \leftarrow P_T^i \cup E_T^i$ ;
18:   $P_V^{i+1} \leftarrow P_V^i \cup E_V^i$ ;
19:  if  $P_T^{i+1} = P_T^i$  and  $P_V^{i+1} = P_V^i$  then
20:    return  $C^*$ ;
21:  end if
22: end for
23: return  $C^*$ ;

```

شکل ۴: الگوریتم SortNet

مخفی و دو عدد از ورودی‌های (دو بعد از دو نمونه‌ی  $x$  و  $y$ ) با هم به اشتراک گذاشته می‌شوند؛ همچنین بایاس‌های لایه‌ی مخفی نیز اشتراک وزن دارند و در مورد وزن های بین لایه‌ی مخفی و خروجی‌ها به در دو وزن از دو نورون متفاوت از لایه‌ی مخفی به دو خروجی به اشتراک گذاشته می‌شود (همانند کاری که در اشتراک وزن بین ورودی‌ها و لایه‌ی مخفی صورت گرفت).

### ۲-۳ یادگیری رتبه‌بندی با SortNet

اکنون که با شبکه‌ای که می‌تواند ارجحیت بین داده‌ها را یادبگیرد آشنا شدیم، به معرفی الگوریتم جهت آموزش این شبکه که باعث می‌شود شبکه‌ی CmpNN بهترین وزن‌های ممکن متناسب با داده‌های را داشته باشد که در نهایت باعث می‌شود که ارجحیت‌بندی بهتری داشته باشیم. الگوریتمی که در اینجا معرفی می‌شود SortNet نام دارد، که مرتبه‌ی اجرای این الگوریتم  $O(n \log n)$  می‌باشد.

در مورد ضرورت داشتن الگوریتم SortNet می‌توان به این نکته اشاره کرد که اگر فرض کنیم به تعداد  $N$  عدد نمونه‌ی آزمایشی داشته باشیم، حال اگر رابطه‌ی ارجحیت هر جفت نمونه‌ی موجود در این دیتاست را داشته باشیم به تعداد  $\binom{N}{2}$  عدد رابطه‌ی ارجحیت خواهیم داشت که آموزش این مقدار نیازمند زمان زیادی می‌باشد، لذا نیاز به الگوریتمی داریم که بتواند داده‌های ارجحیت را به صورت هدفمند برای آموزش شبکه‌ی CmpNN استفاده کند، که این عمل را الگوریتم SortNet انجام می‌دهد که در شکل ۴ آمده است. در این الگوریتم در هر دوره<sup>۲۶</sup> از آموزش، داده‌های آموزش توسط نمونه‌های جدید گسترش پیدا می‌کند. هدف از این کار این است که زیرمجموعه‌ای آموزشی از داده‌های آموزشی و تست انتخاب شود که دارای حداکثر بهره‌ی اطلاعاتی جهت برروزرسانی وزن‌های شبکه‌ی CmpNN باشند. هر مجموعه‌ی آموزشی برای آموزش شبکه‌ی CmpNN متفاوتی استفاده می‌شود. فرض کنید تابعی به نام RankQuality را داریم که میزان کیفیت یک رتبه‌بندی<sup>۲۷</sup>



مختلف استفاده می‌شوند. در این جا از نسخه ی ۲۰۰ این مجموعه دیتاست استفاده شده است که شامل ۳ دیتاست زیر می‌باشد:

| Hidden neurons |            | CmpNN               | Neural Network of [20] |
|----------------|------------|---------------------|------------------------|
| 10             | Test       | <b>87.46 ± 1.67</b> | 50.75 ± 29.11          |
|                | Train      | <b>90.27 ± 1.41</b> | 50.29 ± 29.53          |
|                | Validation | <b>87.09 ± 1.42</b> | 49.56 ± 29.00          |
| 20             | Test       | <b>88.25 ± 0.56</b> | 60.71 ± 12.15          |
|                | Train      | <b>90.73 ± 0.39</b> | 61.43 ± 12.06          |
|                | Validation | <b>88.02 ± 0.38</b> | 60.02 ± 12.22          |
| 30             | Test       | <b>88.21 ± 0.95</b> | 61.36 ± 19.27          |
|                | Train      | <b>90.65 ± 1.78</b> | 61.56 ± 20.24          |
|                | Validation | <b>87.63 ± 1.27</b> | 62.02 ± 18.58          |
| 40             | Test       | <b>87.95 ± 0.74</b> | 68.14 ± 7.15           |
|                | Train      | <b>90.97 ± 1.85</b> | 69.55 ± 7.68           |
|                | Validation | <b>87.93 ± 0.80</b> | 69.14 ± 6.60           |
| 50             | Test       | <b>88.42 ± 1.08</b> | 68.36 ± 12.01          |
|                | Train      | <b>91.40 ± 2.06</b> | 69.64 ± 11.95          |
|                | Validation | <b>88.07 ± 1.36</b> | 68.88 ± 11.90          |

جدول ۲: مقایسه ی عملکرد شبکه ی CmpNN با یک روش دیگر برای یادگیری تابع ارجحیت بروی داده های غیرمتعدی

۱. **TD2003**: شامل ۵۰ مجموعه ی داده متناظر با ۵۰ پرس و جو که هریک شامل ۱۰۰۰ مستند می‌باشند. در این دیتاست هر زوج مرتب «پرس و جو، مستند» توسط ۴۴ مقدار که معمولاً در بازایی اطلاعات<sup>۲۲</sup> استفاده می‌شوند؛ نمایش داده می‌شوند. برچسب های تخصیص یافته به هر مستند نشان دهنده ی میزان ارتباط (Relevant (R) و عدم ارتباط (Not Relevant (NR)) می‌باشد. به ازای هر پرس و جو فقط ۱٪ از مستندات مرتبط با موضوع آن می‌باشند.

۲. **TD2004**: همانند TD2003 می‌باشد با این تفاوت که شامل ۷۵ مجموعه ی داده ای تفاوت می‌باشد.

۳. **OHSUMED**: یک دیتاست مرتبط با کاربردهای پزشکی می‌باشد که شامل ۱۰۶ مجموعه ی مستندات پزشکی با میزان ارتباط موضوعی به ازای پرس و جوهای مختلف می‌باشد. در این دیتاست میزان ارتباط موضوعی هر پرس و جو با هر مستند توسط انسان تعیین شده اند که توسط ۳ مقدار ارتباط (R)، عدم ارتباط (NR) و احتمالاً مرتبط (PR) نشان داده شده اند. مستندات توسط ۲۵ ویژگی نمایش داده شده اند.

| Hiddens |           | TD2003              | TD2004              | OHSUMED             |
|---------|-----------|---------------------|---------------------|---------------------|
| 10      | Accuracy  | <b>92.93 ± 3.11</b> | 97.22 ± 2.25        | <b>94.38 ± 2.73</b> |
|         | Precision | <b>92.95 ± 2.40</b> | 97.15 ± 1.50        | <b>94.93 ± 1.82</b> |
|         | Recall    | <b>92.95 ± 2.41</b> | 97.15 ± 1.50        | <b>94.93 ± 1.82</b> |
| 20      | Accuracy  | 90.66 ± 3.80        | <b>97.97 ± 1.98</b> | 94.28 ± 1.74        |
|         | Precision | 90.11 ± 2.20        | <b>97.64 ± 1.32</b> | 94.11 ± 1.17        |
|         | Recall    | 90.10 ± 2.20        | <b>97.65 ± 1.33</b> | 94.19 ± 1.17        |
| 30      | Accuracy  | 88.65 ± 3.94        | 96.63 ± 2.12        | 93.92 ± 1.45        |
|         | Precision | 89.43 ± 2.29        | 97.08 ± 1.41        | 93.95 ± 0.96        |
|         | Recall    | 89.43 ± 2.29        | 97.08 ± 1.41        | 93.95 ± 0.97        |

جدول ۳: مقایسه ی عملکرد شبکه ی CmpNN با تغییر تعداد نورون های لایه ی مخفی بروی دیتاست های مختلف

| Dataset        |                 | Hidden neurons |
|----------------|-----------------|----------------|
| <b>TD2003</b>  | SortNet MAP     | 20             |
|                | SortNet P@10    | 30             |
|                | SortNet NDCG@10 | 20             |
| <b>TD2004</b>  | SortNet MAP     | 20             |
|                | SortNet P@10    | 10             |
|                | SortNet NDCG@10 | 10             |
| <b>OHSUMED</b> | SortNet MAP     | 20             |
|                | SortNet P@10    | 10             |
|                | SortNet NDCG@10 | 10             |

جدول ۴: تعداد نورون های لایه ی مخفی مورد استفاده در شبکه ی CmpNN در دیتاست های مختلف و توابع ارزیاب کیفیت مختلف

در ابتدای آزمایشات به بررسی و مقایسه ی عملکرد شبکه ی CmpNN با یکی از روش های دیگر بروی یادگیری تابع ارجحیت غیرمتعدی می‌پردازیم که در جدول ۲ آمده است. نتایج میانگینی از نتایج اجرای 5-Fold Cross Validation می‌باشد که در هر اجرا به صورت تصادفی ۱۰،۰۰۰ نمونه جهت آموزش و ۴،۰۰۰ نمونه جهت ارزیابی و ۶،۰۰۰ نمونه جهت تست استفاده شدند. آزمون آماری t تایید کرد که مدل ارائه شده در این مقاله بهبود قابل ملاحظه ای نسبت به روش دیگر داشته است. در جدول ۳ نیز عملکرد CmpNN با تغییر تعداد نورون های لایه ی مخفی بروی ۳ دیتاست TD2003، TD2004 و OHSUMED آورده شده است. در جدول ۴ نیز تعداد نورون های لایه ی مخفی برای دیتاست ها و توابع ارزیاب کیفیت مختلف آورده شده است که مبنای مقایسه های سایر نتایج آزمایشات دیگر این مقاله می‌باشد. در جداول ۵، ۶ و ۷ نتایج اجرای الگوریتم های مختلف به ترتیب بروی دیتاست های TD2003، TD2004 و OHSUMED که با معیارهای P@n و NDCG@n ارزیابی شده اند، نتایج نشان داده اند که الگوریتم معرفی شده (SortNet) توانسته است در هر ۳ دیتاست مورد آزمون، نتایج بهتری از دیگر الگوریتم های مدرن در این زمینه بدست آورد. در جدول ۸ نیز نتایج اجرای الگوریتم های مختلف بروی ۳ دیتاست معرفی شده که با معیار MAP سنجیده شده اند، آورده شده است، همان طور که می‌بینیم الگوریتم معرفی شده با این معیار مقایسه نیز توانسته بهتر از دیگر روش های مدرن عمل کند.

|                 | NDCG@n      |             |             |             |             |             |             |             |             |             | P@n         |             |             |             |             |             |             |             |             |             |
|-----------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|
|                 | n=1         | n=2         | n=3         | n=4         | n=5         | n=6         | n=7         | n=8         | n=9         | n=10        | n=1         | n=2         | n=3         | n=4         | n=5         | n=6         | n=7         | n=8         | n=9         | n=10        |
| RankBoost       | 0.26        | 0.28        | 0.27        | 0.27        | 0.28        | 0.28        | 0.29        | 0.28        | 0.28        | 0.29        | 0.26        | 0.27        | 0.24        | 0.23        | 0.22        | 0.21        | 0.21        | 0.19        | 0.18        | 0.18        |
| RankSVM         | 0.42        | 0.37        | 0.38        | 0.36        | 0.35        | 0.34        | 0.34        | 0.34        | 0.34        | 0.34        | 0.42        | 0.35        | 0.34        | 0.3         | 0.26        | 0.24        | 0.23        | 0.23        | 0.22        | 0.21        |
| Frank-c19.0     | 0.44        | 0.39        | 0.37        | 0.34        | 0.33        | 0.33        | 0.33        | 0.33        | 0.34        | 0.34        | 0.44        | 0.37        | 0.32        | 0.26        | 0.23        | 0.22        | 0.21        | 0.21        | 0.2         | 0.19        |
| ListNet         | 0.46        | 0.43        | 0.41        | 0.39        | 0.38        | 0.39        | 0.38        | 0.37        | 0.38        | 0.37        | 0.46        | 0.42        | 0.36        | 0.31        | 0.29        | 0.28        | 0.26        | 0.24        | 0.23        | 0.22        |
| AdaRank MAP     | 0.42        | 0.32        | 0.29        | 0.27        | 0.24        | 0.23        | 0.22        | 0.21        | 0.2         | 0.19        | 0.42        | 0.31        | 0.27        | 0.23        | 0.19        | 0.16        | 0.14        | 0.13        | 0.11        | 0.1         |
| AdaRank NDCG    | 0.52        | 0.41        | 0.37        | 0.35        | 0.33        | 0.31        | 0.3         | 0.29        | 0.28        | 0.27        | 0.52        | 0.4         | 0.35        | 0.31        | 0.27        | 0.24        | 0.21        | 0.19        | 0.17        | 0.16        |
| SortNet MAP     | <b>0.58</b> | <b>0.46</b> | <b>0.43</b> | <b>0.4</b>  | <b>0.4</b>  | <b>0.39</b> | <b>0.4</b>  | <b>0.39</b> | <b>0.39</b> | <b>0.39</b> | <b>0.58</b> | <b>0.45</b> | <b>0.39</b> | <b>0.33</b> | <b>0.31</b> | <b>0.29</b> | <b>0.28</b> | <b>0.27</b> | <b>0.26</b> | <b>0.24</b> |
| SortNet P@10    | <b>0.44</b> | <b>0.42</b> | <b>0.38</b> | <b>0.37</b> | <b>0.37</b> | <b>0.37</b> | <b>0.37</b> | <b>0.37</b> | <b>0.36</b> | <b>0.36</b> | <b>0.44</b> | <b>0.4</b>  | <b>0.33</b> | <b>0.3</b>  | <b>0.29</b> | <b>0.27</b> | <b>0.26</b> | <b>0.25</b> | <b>0.23</b> | <b>0.22</b> |
| SortNet NDCG@10 | <b>0.5</b>  | <b>0.42</b> | <b>0.41</b> | <b>0.39</b> | <b>0.39</b> | <b>0.39</b> | <b>0.39</b> | <b>0.39</b> | <b>0.38</b> | <b>0.38</b> | <b>0.5</b>  | <b>0.41</b> | <b>0.38</b> | <b>0.34</b> | <b>0.31</b> | <b>0.3</b>  | <b>0.29</b> | <b>0.27</b> | <b>0.26</b> | <b>0.24</b> |

جدول ۵: نتایج اجرای الگوریتم‌های مختلف بروی دیتاست TD2003 براساس معیارهای NDCG@n و P@n

|                 | NDCG@n      |             |             |             |             |             |             |             |             |             | P@n         |             |             |             |             |             |             |             |             |             |
|-----------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|
|                 | n=1         | n=2         | n=3         | n=4         | n=5         | n=6         | n=7         | n=8         | n=9         | n=10        | n=1         | n=2         | n=3         | n=4         | n=5         | n=6         | n=7         | n=8         | n=9         | n=10        |
| RankBoost       | 0.48        | 0.47        | 0.46        | 0.44        | 0.44        | 0.45        | 0.46        | 0.46        | 0.46        | 0.47        | 0.48        | 0.45        | 0.4         | 0.35        | 0.32        | 0.3         | 0.29        | 0.28        | 0.26        | 0.25        |
| RankSVM         | 0.44        | 0.43        | 0.41        | 0.41        | 0.39        | 0.4         | 0.41        | 0.41        | 0.41        | 0.42        | 0.44        | 0.41        | 0.35        | 0.33        | 0.29        | 0.27        | 0.26        | 0.25        | 0.24        | 0.23        |
| FRank           | 0.44        | 0.47        | 0.45        | 0.43        | 0.44        | 0.45        | 0.46        | 0.45        | 0.46        | 0.47        | 0.44        | 0.43        | 0.39        | 0.34        | 0.32        | 0.31        | 0.3         | 0.27        | 0.26        | 0.26        |
| ListNet         | 0.44        | 0.43        | 0.44        | 0.42        | 0.42        | 0.42        | 0.43        | 0.45        | 0.46        | 0.46        | 0.44        | 0.41        | 0.4         | 0.36        | 0.33        | 0.31        | 0.3         | 0.29        | 0.28        | 0.26        |
| AdaRank MAP     | 0.41        | 0.39        | 0.4         | 0.39        | 0.39        | 0.4         | 0.4         | 0.4         | 0.4         | 0.41        | 0.41        | 0.35        | 0.34        | 0.3         | 0.29        | 0.28        | 0.26        | 0.24        | 0.23        | 0.22        |
| AdaRank NDCG    | 0.36        | 0.36        | 0.38        | 0.38        | 0.38        | 0.38        | 0.38        | 0.38        | 0.39        | 0.39        | 0.36        | 0.32        | 0.33        | 0.3         | 0.28        | 0.26        | 0.24        | 0.23        | 0.22        | 0.21        |
| SortNet MAP     | <b>0.47</b> | <b>0.47</b> | <b>0.46</b> | <b>0.46</b> | <b>0.45</b> | <b>0.45</b> | <b>0.45</b> | <b>0.46</b> | <b>0.47</b> | <b>0.48</b> | <b>0.47</b> | <b>0.43</b> | <b>0.38</b> | <b>0.36</b> | <b>0.33</b> | <b>0.3</b>  | <b>0.28</b> | <b>0.28</b> | <b>0.27</b> | <b>0.26</b> |
| SortNet P@10    | <b>0.39</b> | <b>0.43</b> | <b>0.42</b> | <b>0.44</b> | <b>0.44</b> | <b>0.45</b> | <b>0.46</b> | <b>0.46</b> | <b>0.46</b> | <b>0.47</b> | <b>0.39</b> | <b>0.4</b>  | <b>0.36</b> | <b>0.36</b> | <b>0.33</b> | <b>0.32</b> | <b>0.31</b> | <b>0.28</b> | <b>0.27</b> | <b>0.26</b> |
| SortNet NDCG@10 | <b>0.43</b> | <b>0.47</b> | <b>0.46</b> | <b>0.47</b> | <b>0.46</b> | <b>0.47</b> | <b>0.47</b> | <b>0.48</b> | <b>0.48</b> | <b>0.49</b> | <b>0.43</b> | <b>0.43</b> | <b>0.39</b> | <b>0.37</b> | <b>0.34</b> | <b>0.32</b> | <b>0.31</b> | <b>0.29</b> | <b>0.28</b> | <b>0.27</b> |

جدول ۶: نتایج اجرای الگوریتم‌های مختلف بروی دیتاست TD2004 براساس معیارهای NDCG@n و P@n

|                 | NDCG@n      |             |             |             |             |             |             |             |             |             | P@n         |             |             |             |             |             |             |             |             |             |
|-----------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|
|                 | n=1         | n=2         | n=3         | n=4         | n=5         | n=6         | n=7         | n=8         | n=9         | n=10        | n=1         | n=2         | n=3         | n=4         | n=5         | n=6         | n=7         | n=8         | n=9         | n=10        |
| RankBoost       | 0.5         | 0.48        | 0.47        | 0.46        | 0.45        | 0.44        | 0.44        | 0.44        | 0.43        | 0.44        | 0.6         | 0.6         | 0.59        | 0.56        | 0.54        | 0.52        | 0.52        | 0.5         | 0.49        | 0.5         |
| RankSVM         | 0.5         | 0.48        | 0.46        | 0.46        | 0.46        | 0.45        | 0.45        | 0.44        | 0.44        | 0.44        | 0.63        | 0.62        | 0.59        | 0.58        | 0.58        | 0.56        | 0.54        | 0.52        | 0.52        | 0.51        |
| Frank-c4.2      | 0.54        | 0.51        | 0.5         | 0.48        | 0.47        | 0.46        | 0.45        | 0.45        | 0.44        | 0.44        | 0.67        | 0.62        | 0.62        | 0.58        | 0.56        | 0.53        | 0.51        | 0.5         | 0.5         | 0.49        |
| ListNet         | 0.52        | 0.5         | 0.48        | 0.47        | 0.47        | 0.45        | 0.45        | 0.45        | 0.45        | 0.45        | 0.64        | 0.63        | 0.6         | 0.58        | 0.57        | 0.54        | 0.53        | 0.52        | 0.51        | 0.51        |
| AdaRank.MAP     | 0.54        | 0.5         | 0.48        | 0.47        | 0.46        | 0.45        | 0.44        | 0.44        | 0.44        | 0.44        | 0.66        | 0.6         | 0.58        | 0.57        | 0.54        | 0.53        | 0.51        | 0.5         | 0.5         | 0.49        |
| AdaRank.NDCG    | 0.51        | 0.47        | 0.46        | 0.46        | 0.44        | 0.44        | 0.44        | 0.44        | 0.44        | 0.44        | 0.63        | 0.6         | 0.57        | 0.56        | 0.53        | 0.53        | 0.52        | 0.51        | 0.5         | 0.49        |
| MHR-BC          | 0.55        | 0.49        | 0.49        | 0.48        | 0.47        | 0.46        | 0.45        | 0.44        | 0.44        | 0.44        | 0.65        | 0.61        | 0.61        | 0.59        | 0.57        | 0.55        | 0.53        | 0.51        | 0.5         | 0.5         |
| SortNet MAP     | <b>0.52</b> | <b>0.48</b> | <b>0.47</b> | <b>0.46</b> | <b>0.45</b> | <b>0.45</b> | <b>0.44</b> | <b>0.44</b> | <b>0.44</b> | <b>0.44</b> | <b>0.63</b> | <b>0.58</b> | <b>0.57</b> | <b>0.56</b> | <b>0.55</b> | <b>0.55</b> | <b>0.53</b> | <b>0.52</b> | <b>0.51</b> | <b>0.5</b>  |
| SortNet P@10    | <b>0.49</b> | <b>0.43</b> | <b>0.44</b> | <b>0.43</b> | <b>0.42</b> | <b>0.42</b> | <b>0.42</b> | <b>0.42</b> | <b>0.42</b> | <b>0.42</b> | <b>0.62</b> | <b>0.57</b> | <b>0.57</b> | <b>0.55</b> | <b>0.53</b> | <b>0.51</b> | <b>0.51</b> | <b>0.51</b> | <b>0.5</b>  | <b>0.49</b> |
| SortNet NDCG@10 | <b>0.52</b> | <b>0.48</b> | <b>0.45</b> | <b>0.45</b> | <b>0.44</b> | <b>0.44</b> | <b>0.44</b> | <b>0.44</b> | <b>0.43</b> | <b>0.43</b> | <b>0.64</b> | <b>0.61</b> | <b>0.57</b> | <b>0.57</b> | <b>0.55</b> | <b>0.54</b> | <b>0.53</b> | <b>0.52</b> | <b>0.5</b>  | <b>0.49</b> |

جدول ۷: نتایج اجرای الگوریتم‌های مختلف بروی دیتاست OHSUMED براساس معیارهای NDCG@n و P@n

## پانویس‌ها

- <sup>1</sup> Rank
- <sup>2</sup> Preference Learning
- <sup>3</sup> Machine Learning
- <sup>4</sup> Order
- <sup>5</sup> Preference Information
- <sup>6</sup> Qualitative decision theory
- <sup>7</sup> Non-monotonic reasoning
- <sup>8</sup> Constraint satisfaction
- <sup>9</sup> Planning
- <sup>10</sup> Ranking Order
- <sup>11</sup> Object Ranking
- <sup>12</sup> Label Ranking
- <sup>13</sup> Instance Ranking
- <sup>14</sup> Total Strict Order
- <sup>15</sup> Order
- <sup>16</sup> Alternatives
- <sup>17</sup> Format
- <sup>18</sup> Index Permutation
- <sup>19</sup> Classification
- <sup>20</sup> Multi-label classification
- <sup>21</sup> Learning Utility Functions
- <sup>22</sup> Learning Preference Relations
- <sup>23</sup> Feedforward
- <sup>24</sup> Reflexivity
- <sup>25</sup> Anti-symmetry
- <sup>26</sup> Iteration
- <sup>27</sup> Rank
- <sup>28</sup> Iteration
- <sup>29</sup> Document
- <sup>30</sup> Query
- <sup>31</sup> Ideal Ordering
- <sup>32</sup> Information Retrieval

|                 | TD2003       | TD2004       | OSHUMED      |
|-----------------|--------------|--------------|--------------|
| RankBoost       | 0.212        | 0.384        | 0.44         |
| RankSVM         | 0.256        | 0.35         | 0.447        |
| Frank-c4.2      | 0.245        | 0.381        | 0.446        |
| ListNet         | 0.273        | 0.372        | 0.45         |
| AdaRank.MAP     | 0.137        | 0.331        | 0.442        |
| AdaRank.NDCG    | 0.185        | 0.299        | 0.442        |
| MHR-BC          | NA           | NA           | 0.44         |
| SortNet MAP     | <b>0.307</b> | <b>0.391</b> | <b>0.442</b> |
| SortNet P@10    | <b>0.256</b> | <b>0.381</b> | <b>0.438</b> |
| SortNet NDCG@10 | <b>0.297</b> | <b>0.402</b> | <b>0.44</b>  |

جدول ۸: نتایج اجرای الگوریتم‌های مختلف بروی ۳ دیتاست مورد استفاده براساس معیار مقایسه‌ی MAP

## ۴ نتیجه‌گیری

در این گزارش ابتدا به بیان مفاهیم پایه‌ی یادگیری ارجحیت پرداختیم سپس با مروری خلاصه بر برخی کارهای انجام شده در زمینه‌ی یادگیری ارجحیت با تمرکز بروی مقاله‌ی اصلی سمینار به معرفی معماری جدیدی از شبکه‌ای عصبی که می‌تواند مدل ارجحیت بین داده‌ها را یادبگیرد پرداختیم سپس الگوریتمی که برای یادگیری بهینه‌ی شبکه استفاده می‌شود را شرح دادیم و در نهایت به ارائه نتایج حاصل از اجرای این شبکه و الگوریتم معرفی شده و مقایسه‌ی این نتایج با اجرای دیگر الگوریتم‌های مدرن در این زمینه پرداختیم و نشان دادیم که روش ارائه شده توانسته است با هر ۳ معیار ارزیابی کیفیت بهتر از دیگر روش عمل کند.

## مراجع

- [1] Rigutini, L., Papini, T., Maggini, M., Scarselli, F., "SortNet: Learning to Rank by a Neural Preference Function," in Neural Networks, IEEE Transactions on , vol.22, no.9, pp.1368-1380, Sept. 2011
- [2] Han-Jiang Lai, Yan Pan, Yong Tang, Rong Yu, "FSMRank: Feature Selection Algorithm for Learning to Rank," in Neural Networks and Learning Systems, IEEE Transactions on , vol.24, no.6, pp.940-952, June 2013
- [3] Fei Gao, Dacheng Tao, Xinbo Gao, Xuelong Li, "Learning to Rank for Blind Image Quality Assessment," in Neural Networks and Learning Systems, IEEE Transactions on , vol.26, no.10, pp.2275-2290, Oct. 2015
- [4] J. Furnkranz and E. Hullermeier, "Encyclopedia of Machine Learning". Springer, 2010, ch. Preference Learning, pp. 789–795.
- [5] J. Furnkranz and E. Hullermeier, "Preference Learning". Kunstliche Intelligenz, pp. 60–61, 2005.